

Procesamiento de Señales de Audio y Speech Enhancement

Índice

1. Introducción general	3
2. Lista de símbolos y abreviaciones	3
2.1. Símbolos principales	3
2.2. Abreviaciones	4
3. Clase 1: formulación general del problema	4
4. Clase 2: probabilidad y estadística necesarias	5
4.1. Esperanza matemática	5
4.2. Varianza	5
4.3. Covarianza	6
4.4. SNR	6
4.5. Esperanza condicional	6
4.6. Ley de la esperanza total	6
4.7. Ley de la varianza total	7
5. Clase 3: mejor estimador y MMSE	7
5.1. Interpretación	7
5.2. Error mínimo	7
6. Clase 4: Wiener filter	8
6.1. Interpretación	8
6.2. Versión tiempo-frecuencia	8
7. Clase 5: STFT	9

7.1. Interpretación	9
7.2. Reconstrucción	9
8. Clase 6: espectrograma y lectura de voz	9
8.1. Interpretación visual	9
8.2. Patrones importantes	10
9. Clase 7: formantes y modelo fuente-filtro	10
9.1. Pitch y formantes	10
9.2. Diferencia	10
10. Clase 8: MFCC	10
10.1. Pipeline	11
10.2. Preénfasis	11
10.3. Espectro de potencia	11
10.4. Banco de filtros Mel	11
10.5. Escala Mel	11
10.6. Logaritmo	12
10.7. DCT	12
10.8. Interpretación	12
11. Clase 9: otras características de audio	12
11.1. Zero Crossing Rate	12
11.2. Amplitude Envelope	12
11.3. RMS	12
11.4. Spectral Centroid	13
11.5. Spectral Bandwidth	13
11.6. Spectral Rolloff	13
11.7. Spectral Flux	13
12. Clase 10: elección de features	13
12.1. Ejemplos	13

1. Introducción general

Este documento resume las clases sobre procesamiento de señales de audio, extracción de características y fundamentos de *speech enhancement*. El objetivo central es entender cómo recuperar una señal de voz limpia a partir de una observación contaminada por ruido.

La idea base es:

$$y = x + v \tag{1}$$

donde la señal observada y es la suma de la señal deseada x y el ruido v .

2. Lista de símbolos y abreviaciones

2.1. Símbolos principales

Símbolo	Significado
x	Señal limpia o señal deseada, usualmente voz.
v	Ruido o perturbación no deseada.
y	Señal observada o ruidosa.
$\hat{x}$	Estimación de la señal limpia.
e	Error de estimación.
t	Índice temporal discreto.
n	Índice de frame o ventana temporal en STFT/MFCC.
k	Índice de frecuencia o bin espectral.
f	Frecuencia.
$\mathbf{y}$	Vector de observaciones.
$\mathbf{x}$	Vector de señal deseada.
$\mathbf{v}$	Vector de ruido.
$\mathbf{d}$	<i>Steering vector</i> , describe la llegada espacial de la señal a varios micrófonos.
$\mathbf{w}$	Vector de pesos de un beamformer o filtro multicanal.
$E[\cdot]$	Esperanza matemática o valor esperado.
$\text{var}(\cdot)$	Varianza.
$\text{cov}(\cdot, \cdot)$	Covarianza.
R_{yy}	Matriz de autocorrelación o covarianza de la observación.
$\mathbf{r}_{yx}$	Vector de correlación cruzada entre observación y señal deseada.
R_x	Matriz de covarianza de la señal de voz.
R_v	Matriz de covarianza del ruido.
H	Ganancia de un filtro en un caso escalar.
$H(k, n)$	Ganancia en el dominio tiempo-frecuencia para el bin k y frame n .

$X(k, n)$	STFT de la señal limpia.
$Y(k, n)$	STFT de la señal observada.
$V(k, n)$	STFT del ruido.
F_0	Frecuencia fundamental o pitch.
F_1, F_2, F_3	Primeros formantes del tracto vocal.
ρ	Coefficiente de correlación de Pearson.
ρ^2	Correlación cuadrada o fuerza de relación lineal.
$\gamma_{X Y}^2$	Coefficiente de determinación entre X y Y .
σ_x^2	Varianza o potencia de la señal x .
σ_v^2	Varianza o potencia del ruido v .

2.2. Abreviaciones

Abreviación	Significado
DSP	<i>Digital Signal Processing</i> = Procesamiento Digital de Señales.
STFT	<i>Short-Time Fourier Transform.</i>
ISTFT	<i>Inverse Short-Time Fourier Transform.</i>
FFT	<i>Fast Fourier Transform.</i>
MMSE	<i>Minimum Mean Square Error.</i>
MSE	<i>Mean Square Error.</i>
SNR	<i>Signal-to-Noise Ratio.</i>
iSNR	<i>input SNR</i> = SNR de entrada.
SNR _{out}	SNR de salida.
FIR	<i>Finite Impulse Response.</i>
MFCC	<i>Mel-Frequency Cepstral Coefficients.</i>
ZCR	<i>Zero Crossing Rate.</i>
RMS	<i>Root Mean Square.</i>
ASR	<i>Automatic Speech Recognition.</i>
VAD	<i>Voice Activity Detection.</i>
MVDR	<i>Minimum Variance Distortionless Response.</i>
CNN	<i>Convolutional Neural Network.</i>
TTS	<i>Text To Speech.</i>
LPC	<i>Linear Predictive Coding.</i>
SPCC	<i>Squared Pearson Correlation Coefficient.</i>
CQCC	<i>Constant-Q Cepstral Coefficients.</i>
ANC	<i>Active Noise Control.</i>

3. Clase 1: formulación general del problema

La formulación más general del problema de mejora de voz es:

$$y = x + v \quad (2)$$

Interpretación:

- x : voz limpia.
- v : ruido.
- y : señal capturada por el micrófono.

El objetivo es construir una estimación $\hat{x}$ que sea lo más cercana posible a x .

En dominio temporal:

$$y_t = x_t + v_t \quad (3)$$

En forma vectorial:

$$\mathbf{y}_t = [y_t, y_{t-1}, \dots, y_{t-L+1}]^T \quad (4)$$

donde L es la longitud de la ventana temporal.

En dominio tiempo-frecuencia, usando STFT:

$$Y(k, n) = X(k, n) + V(k, n) \quad (5)$$

En el caso multicanal:

$$\mathbf{y}(f) = X(f)\mathbf{d}(f) + \mathbf{v}(f) \quad (6)$$

4. Clase 2: probabilidad y estadística necesarias

4.1. Esperanza matemática

La esperanza de una variable aleatoria X es:

$$E[X] \quad (7)$$

Representa el valor promedio esperado.

4.2. Varianza

La varianza mide la dispersión de una variable:

$$\text{var}(X) = E[(X - E[X])^2] \quad (8)$$

Si $E[X] = 0$, entonces:

$$\text{var}(X) = E[X^2] \quad (9)$$

En audio, la varianza suele interpretarse como potencia.

4.3. Covarianza

La covarianza entre dos variables X y Y es:

$$\text{cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] \quad (10)$$

Si ambas tienen media cero:

$$\text{cov}(X, Y) = E[XY] \quad (11)$$

4.4. SNR

La relación señal a ruido se define como:

$$\text{SNR} = \frac{\text{var}(X)}{\text{var}(V)} \quad (12)$$

Interpretación:

- SNR alto: la voz domina.
- SNR bajo: el ruido domina.

4.5. Esperanza condicional

La esperanza condicional es:

$$E[X|Y] \quad (13)$$

Significa el mejor promedio esperado de X sabiendo Y .

4.6. Ley de la esperanza total

$$E[X] = E[E[X|Y]] \quad (14)$$

4.7. Ley de la varianza total

$$\text{var}(X) = E[\text{var}(X|Y)] + \text{var}(E[X|Y]) \quad (15)$$

Interpretación:

- $E[\text{var}(X|Y)]$: incertidumbre que queda después de observar Y .
- $\text{var}(E[X|Y])$: parte de X explicada por Y .

5. Clase 3: mejor estimador y MMSE

Definimos el error de estimación como:

$$e = X - \hat{X} \quad (16)$$

El criterio MMSE consiste en minimizar:

$$E[|X - \hat{X}|^2] \quad (17)$$

El mejor estimador en este sentido es:

$$\hat{X} = E[X|Y] \quad (18)$$

Este es el estimador óptimo en el sentido de mínimo error cuadrático medio.

5.1. Interpretación

- No se trata de adivinar la señal limpia.
- Se trata de usar la estadística del problema para inferir la mejor estimación posible.

5.2. Error mínimo

El error mínimo se relaciona con el coeficiente de determinación:

$$\text{MMSE} = \text{var}(X) (1 - \gamma_{X|Y}^2) \quad (19)$$

donde $\gamma_{X|Y}^2$ mide cuánto de X puede explicarse a partir de Y .

6. Clase 4: Wiener filter

Si restringimos el estimador a una forma lineal:

$$\hat{X} = HY \quad (20)$$

el valor óptimo de H es:

$$H = \frac{\text{var}(X)}{\text{var}(X) + \text{var}(V)} \quad (21)$$

Como:

$$\text{var}(Y) = \text{var}(X) + \text{var}(V) \quad (22)$$

también puede escribirse como:

$$H = \frac{\text{var}(X)}{\text{var}(Y)} \quad (23)$$

En términos de SNR:

$$H = \frac{\text{SNR}}{1 + \text{SNR}} \quad (24)$$

6.1. Interpretación

- Si la voz domina, $H \approx 1$, y el componente se conserva.
- Si el ruido domina, $H \approx 0$, y el componente se atenúa.

6.2. Versión tiempo-frecuencia

$$\hat{X}(k, n) = H(k, n)Y(k, n) \quad (25)$$

con

$$H(k, n) = \frac{P_X(k, n)}{P_X(k, n) + P_V(k, n)} \quad (26)$$

donde:

- $P_X(k, n)$: potencia estimada de la voz.
- $P_V(k, n)$: potencia estimada del ruido.

7. Clase 5: STFT

La STFT permite analizar una señal localmente en tiempo y frecuencia.

$$X(k, n) = \sum_m x[m]w[m - nR]e^{-j2\pi km/N} \quad (27)$$

donde:

- $x[m]$: señal en tiempo.
- $w[\cdot]$: ventana.
- R : desplazamiento entre frames (*hop size*).
- N : tamaño de FFT.
- k : bin de frecuencia.
- n : índice de frame.
- j : unidad imaginaria.

7.1. Interpretación

La STFT responde a la pregunta: *qué frecuencias están presentes y en qué instante*.

7.2. Reconstrucción

Después del procesamiento, se usa ISTFT para volver al dominio temporal:

$$\hat{x}[n] = \text{ISTFT}(\hat{X}(k, n)) \quad (28)$$

8. Clase 6: espectrograma y lectura de voz

El espectrograma es una representación visual de:

$$|X(k, n)| \quad (29)$$

8.1. Interpretación visual

- Eje horizontal: tiempo.
- Eje vertical: frecuencia.
- Intensidad o color: energía.

8.2. Patrones importantes

- Líneas horizontales: armónicos.
- Bandas anchas: formantes.
- Línea vertical intensa: evento impulsivo.
- Fondo brillante: ruido de fondo.

9. Clase 7: formantes y modelo fuente-filtro

La voz puede modelarse como:

$$\text{Speech} = \text{Source} \times \text{Filter} \quad (30)$$

En frecuencia:

$$S(f) = G(f)H(f) \quad (31)$$

donde:

- $G(f)$: excitación glotal o fuente.
- $H(f)$: respuesta del tracto vocal.

9.1. Pitch y formantes

- F_0 : frecuencia fundamental, asociada a vibración de cuerdas vocales.
- F_1, F_2, F_3 : formantes, resonancias del tracto vocal.

9.2. Diferencia

- Pitch: asociado a periodicidad.
- Formantes: asociados a la forma del tracto vocal y a la identidad de vocales.

10. Clase 8: MFCC

Los MFCC son coeficientes cepstrales en escala Mel.

10.1. Pipeline

1. Preénfasis.
2. Framing.
3. Windowing.
4. FFT.
5. Espectro de potencia.
6. Banco de filtros Mel.
7. Logaritmo.
8. DCT.

10.2. Preénfasis

$$y[n] = x[n] - \alpha x[n - 1] \quad (32)$$

donde α suele ser cercano a 0,95.

10.3. Espectro de potencia

$$P(k) = |X(k)|^2 \quad (33)$$

10.4. Banco de filtros Mel

$$E_m = \sum_k P(k) H_m(k) \quad (34)$$

donde:

- E_m : energía en el filtro Mel m .
- $H_m(k)$: respuesta del filtro Mel m en el bin k .

10.5. Escala Mel

$$\text{mel} = 2595 \log_{10} \left(1 + \frac{f}{700} \right) \quad (35)$$

10.6. Logaritmo

$$\log(E_m) \quad (36)$$

10.7. DCT

$$c_n = \sum_m \log(E_m) \cos \left[\frac{\pi n}{M} (m + 0,5) \right] \quad (37)$$

donde:

- c_n : coeficiente MFCC número n .
- M : número de filtros Mel.

10.8. Interpretación

MFCC resume la envolvente espectral, no la forma de onda original.

11. Clase 9: otras características de audio

11.1. Zero Crossing Rate

$$\text{ZCR} = \frac{1}{N} \sum |\text{sign}(x[n]) - \text{sign}(x[n-1])| \quad (38)$$

Mide cuántas veces la señal cambia de signo.

11.2. Amplitude Envelope

$$AE[n] = |x[n]| \quad (39)$$

Representa la variación de la amplitud de la señal a lo largo del tiempo. Describe cómo evoluciona la energía sonora, mostrando ataques, sostenimientos y decaimientos del sonido.

11.3. RMS

$$\text{RMS} = \sqrt{\frac{1}{N} \sum x[n]^2} \quad (40)$$

Mide energía efectiva o nivel de amplitud.

11.4. Spectral Centroid

$$\text{Centroid} = \frac{\sum f_k S(k)}{\sum S(k)} \quad (41)$$

Mide el brillo espectral.

11.5. Spectral Bandwidth

$$\text{BW} = \sqrt{\frac{\sum (f_k - \mu)^2 S(k)}{\sum S(k)}} \quad (42)$$

donde μ es el centroide espectral.

11.6. Spectral Rolloff

$$\sum_{k=0}^{k_r} S(k) = 0,85 \sum_k S(k) \quad (43)$$

k_r es el bin donde se acumula el 85 % de la energía.

11.7. Spectral Flux

$$\text{Flux} = \sum (S_t(k) - S_{t-1}(k))^2 \quad (44)$$

Mide cuánto cambia el espectro entre frames.

12. Clase 10: elección de features

No existe una característica universalmente mejor. La mejor feature depende del problema.

12.1. Ejemplos

- Emociones: pitch, energía, MFCC.
- Identificación de hablante: MFCC, formantes, embeddings.

- Clasificación de ruido: centroid, bandwidth, rolloff, MFCC.
- Wake words: MFCC o log-mel spectrogram.
- Música: chroma, MFCC, flux.