

Fundamentos de Speaker Recognition

Enfoque para Proyecto de Voz Forense y Comparación de Modelos de Deep Learning

Índice

1. Introducción General	3
2. Fundamentos de Speaker Recognition	3
2.1. ¿Por qué la voz identifica personas?	3
2.2. Variabilidad	4
3. Identificación vs Verificación	4
3.1. Identificación	4
3.2. Verificación	4
3.3. Comparación	5
3.4. Importancia forense	5
4. Tipos de Reconocimiento	5
4.1. Closed-set	5
4.2. Open-set	5
4.3. Comparación	5
4.4. 1:1 vs 1:N	6
4.5. Importancia para forense	6
5. Enrollment vs Test	6
5.1. Enrollment	6
5.2. Test / Probe Audio	6
5.3. Base de Referencia	7
5.4. Threshold	7
5.5. Errores clásicos	7
6. Pipeline Forense Completo	7
6.1. 1. Audio	8
6.2. 2. Preprocessing	8
6.3. 3. Features	8
6.4. 4. Model	9

6.5.	5. Embedding	9
6.6.	6. Score	9
6.7.	7. Decisión	9
7.	Importancia del Pipeline en Voz Forense	10
8.	Qué Debes Considerar al Comparar Modelos de Deep Learning	10

1. Introducción General

Speaker Recognition es el área que busca reconocer la identidad de una persona mediante su voz.

La tarea central no es reconocer *qué dice* una persona, sino *quién está hablando*. Esto lo distingue de:

- **ASR (Automatic Speech Recognition):** reconoce palabras.
- **Emotion Recognition:** detecta emociones.
- **Language Identification:** detecta idioma.
- **Speaker Recognition:** detecta identidad vocal.

La voz contiene múltiples capas de información:

- Contenido lingüístico.
- Rasgos fisiológicos.
- Hábitos conductuales de habla.
- Ruido y canal.
- Estado emocional o físico.

El objetivo del reconocimiento de locutor es aislar la información útil para distinguir personas.

2. Fundamentos de Speaker Recognition

2.1. ¿Por qué la voz identifica personas?

Porque depende de dos grandes grupos de factores:

Factores fisiológicos

- Tracto vocal.
- Cuerdas vocales.
- Resonancias naturales.
- Anatomía vocal.

Factores conductuales

- Ritmo al hablar.
- Entonación.
- Pronunciación.
- Pausas.
- Hábitos articulatorios.

2.2. Variabilidad

La misma persona no siempre suena igual. Cambia por:

- Enfermedad.
- Estrés.
- Edad.
- Fatiga.
- Emoción.
- Micrófono.
- Ruido.

Por eso, la voz no es una huella perfecta e inmutable.

3. Identificación vs Verificación

3.1. Identificación

Pregunta principal:

¿Quién está hablando?

Se compara una muestra contra múltiples identidades conocidas.

Ejemplo: entre 10 sospechosos, determinar cuál habló.

3.2. Verificación

Pregunta principal:

¿Esta voz pertenece a esta persona específica?

Comparación uno a uno.

Ejemplo: ¿la grabación pertenece a Carlos?

3.3. Comparación

Aspecto	Identificación	Verificación
Pregunta	¿Quién habla?	¿Es esta persona?
Comparación	1 vs N	1 vs 1
Salida	Identidad o ranking	Sí / No
Uso forense	Búsqueda inicial	Comparación principal

3.4. Importancia forense

En voz forense, la tarea más importante suele ser:

evidencia vs sospechoso

Esto corresponde a **speaker verification**.

4. Tipos de Reconocimiento

4.1. Closed-set

El sistema asume que la voz sí pertenece a alguien dentro de la base registrada.

No existe opción “desconocido”.

$$\hat{y} \in \{s_1, s_2, \dots, s_n\}$$

4.2. Open-set

La voz puede no pertenecer a nadie registrado.

El sistema debe decidir:

- Coincide con alguien.
- No coincide con nadie.

4.3. Comparación

Aspecto	Closed-set	Open-set
¿Siempre está en la base?	Sí	No necesariamente
Opción desconocido	No	Sí
Dificultad	Menor	Mayor
Realismo forense	Bajo	Alto

4.4. 1:1 vs 1:N

1:1

Una muestra contra una referencia.

¿Es Carlos?

1:N

Una muestra contra muchas referencias.

¿Con cuál coincide mejor?

4.5. Importancia para forense

Los escenarios más realistas son:

- **Open-set 1:1:** evidencia vs sospechoso.
- **Open-set 1:N:** búsqueda de candidatos.

5. Enrollment vs Test

5.1. Enrollment

Es el proceso de crear una referencia del hablante.

No es entrenamiento del modelo.

Es registrar una persona usando un modelo ya entrenado.

Salida típica:

- Embedding de referencia.
- Plantilla.
- Perfil del hablante.

5.2. Test / Probe Audio

Es la muestra nueva que se quiere comparar.

En forense:

- **Enrollment:** voz conocida del sospechoso.
- **Probe:** voz de evidencia.

5.3. Base de Referencia

Colección de perfiles contra los cuales se compara:

- Una persona (1:1).
- Muchas personas (1:N).

5.4. Threshold

Es el valor de corte para convertir score en decisión:

$$s \geq t \Rightarrow \text{Aceptar}$$

$$s < t \Rightarrow \text{Rechazar}$$

donde:

- $s = \text{score}$.
- $t = \text{threshold}$.

5.5. Errores clásicos

- **False Acceptance (FA):** aceptar impostor.
- **False Rejection (FR):** rechazar genuino.

Si sube el threshold:

- Baja FA.
- Sube FR.

Si baja el threshold:

- Sube FA.
- Baja FR.

6. Pipeline Forense Completo

Audio $\rightarrow$ Preprocessing $\rightarrow$ Features $\rightarrow$ Model $\rightarrow$ Embedding $\rightarrow$ Score $\rightarrow$ Decisión

6.1. 1. Audio

Materia prima:

- Llamadas.
- WhatsApp.
- Micrófono ambiente.
- Evidencia.
- Muestras de referencia.

Problemas comunes:

- Ruido.
- Compresión.
- Reverberación.
- Solapamiento de hablantes.

6.2. 2. Preprocessing

Preparación del audio:

- Conversión de formato.
- Resampling.
- Normalización.
- VAD.
- Segmentación.
- Reducción de ruido.

6.3. 3. Features

Representaciones acústicas extraídas de la señal:

- MFCC.
- Log-Mel Filterbanks.
- PLP.

Capturan:

- Forma espectral.
- Energía por bandas.
- Resonancias.

6.4. 4. Model

Red o sistema que transforma features en representaciones útiles.

Ejemplos:

- GMM-UBM.
- i-vectors.
- x-vectors.
- ECAPA-TDNN.
- ResNet Speaker Encoder.

6.5. 5. Embedding

Vector compacto que resume la identidad vocal.

Buen embedding debe tener:

- Separación entre hablantes.
- Robustez a ruido.
- Consistencia intra-hablante.
- Generalización.

6.6. 6. Score

Comparación entre referencia y probe.

Ejemplos:

- Cosine Similarity.
- PLDA Score.
- Distancia Euclidiana transformada.

6.7. 7. Decisión

Salida final:

- Aceptar / rechazar.
- Ranking.
- Unknown.
- Score para análisis pericial.

7. Importancia del Pipeline en Voz Forense

En forense, el sistema no debe verse como caja negra.

Cada etapa puede introducir:

- Sesgos.
- Pérdida de información.
- Falsos positivos.
- Falsos negativos.
- Dependencia de canal.

Por ello se requiere trazabilidad:

- Qué audio se usó.
- Cómo fue procesado.
- Qué modelo generó embeddings.
- Cómo se calculó el score.
- Cómo se interpretó.

8. Qué Debes Considerar al Comparar Modelos de Deep Learning

No basta con comparar accuracy.

Debes controlar:

- Mismo dataset.
- Mismo preprocessing.
- Mismo protocolo enrollment/test.
- Mismo scoring.
- Mismo criterio de threshold.

Además evaluar robustez en:

- Audio corto.
- Ruido.
- Teléfono.
- Distinto canal.
- Distinta sesión.
- Open-set real.