

Espectrogramas y Mel-Espectrogramas

Índice

1. Espectrograma	3
1.1. Definición conceptual	3
1.2. Motivación	3
2. Transformada de Fourier de Tiempo Corto (STFT)	3
2.1. Definición general	3
2.2. Versión discreta	4
3. Frames	4
3.1. Qué es un frame	4
3.2. Interpretación	4
4. Frame Size, Win Length y FFT Size	5
4.1. Frame Size	5
4.2. Win Length	5
4.3. n_{fft}	5
4.4. Zero-padding	5
5. Hop Size y Overlap	6
5.1. Hop Size	6
5.2. Interpretación	6
5.3. Overlap	6
6. Windowing	6
6.1. Motivación	6
6.2. Idea matemática	7
6.3. Efecto del windowing	7
7. Tipos de ventanas	7
7.1. Ventana rectangular	7
7.2. Ventana Hann	7
7.3. Ventana Hamming	8
7.4. Ventanas Blackman y familia	8

8. Resolución Tiempo–Frecuencia	8
8.1. Resolución en frecuencia	8
8.2. Resolución temporal	8
8.3. Trade-off	8
9. Magnitud, Potencia y Logaritmo	9
9.1. Espectrograma de magnitud	9
9.2. Espectrograma de potencia	9
9.3. Espectrograma logarítmico	9
10. Interpretación del Espectrograma	9
11. Reconstrucción e ISTFT	9
12. Escala Mel	10
12.1. Definición	10
12.2. Interpretación	10
13. Banco de Filtros Mel	10
13.1. Idea general	10
13.2. Construcción	11
13.3. Filtro triangular típico	11
13.4. Interpretación	11
14. Mel-Espectrograma	11
14.1. Definición	11
14.2. Forma matricial	12
15. Qué gana y qué pierde el Mel-Espectrograma	12
15.1. Ventajas	12
15.2. Desventajas	12
16. Relación entre Espectrograma y Mel-Espectrograma	13
17. Parámetros Fundamentales del Mel-Espectrograma	13
17.1. n_{mels}	13
17.2. $f_{\text{mín}}$ y $f_{\text{máx}}$	13
17.3. Power	13
17.4. Compresión logarítmica	14
18. Interpretación del Mel-Espectrograma	14
19. Resumen Comparativo	14

1. Espectrograma

1.1. Definición conceptual

Un **espectrograma** es una representación bidimensional de una señal donde:

- el eje horizontal corresponde al **tiempo**,
- el eje vertical corresponde a la **frecuencia**,
- la intensidad o color representa la **magnitud, energía o potencia** de la señal en cada región tiempo–frecuencia.

A diferencia de una transformada de Fourier global, el espectrograma permite observar **cómo evolucionan las componentes frecuenciales a lo largo del tiempo**. Esta propiedad es esencial en señales de voz, música y audio general, donde la estructura espectral cambia continuamente.

1.2. Motivación

La Transformada de Fourier clásica responde a la pregunta:

“¿Qué frecuencias tiene la señal?”

pero no responde a:

“¿En qué momento aparecen esas frecuencias?”

Para resolver esto se analiza la señal por segmentos cortos, y a cada segmento se le calcula su contenido espectral. Esto da lugar a la STFT y, posteriormente, al espectrograma.

2. Transformada de Fourier de Tiempo Corto (STFT)

2.1. Definición general

La STFT consiste en multiplicar la señal por una ventana localizada en el tiempo y aplicar una transformada de Fourier a ese fragmento. Matemáticamente, en tiempo continuo:

$$S(f, t) = \int_{\mathbb{R}} x(\xi) \overline{w(\xi - t)} e^{-j2\pi f\xi} d\xi$$

donde:

- $x(\xi)$ es la señal,
- $w(\xi - t)$ es la ventana centrada alrededor del tiempo t ,
- f es la frecuencia,
- $S(f, t)$ es la representación tiempo–frecuencia resultante.

2.2. Versión discreta

Para una señal discreta $x[n]$, una forma típica de la STFT es:

$$X[k, m] = \sum_{n=0}^{L-1} x[n + mh] w[n] e^{-j2\pi kn/N}$$

donde:

- m es el índice del frame,
- k es el índice del bin de frecuencia,
- L es la longitud efectiva de la ventana,
- h es el **hop size**,
- N es el tamaño de la FFT,
- $w[n]$ es la ventana.

El resultado $X[k, m]$ es una matriz compleja que contiene:

- $|X[k, m]|$: magnitud,
- $\angle X[k, m]$: fase.

3. Frames

3.1. Qué es un frame

Un **frame** es un segmento corto de la señal sobre el cual se calcula una STFT local. La hipótesis es que, dentro de ese pequeño intervalo, la señal puede considerarse aproximadamente estacionaria.

Si la señal es $x[n]$, entonces el frame m -ésimo puede verse como:

$$x_m[n] = x[n + mh] w[n]$$

Cada frame produce una columna del espectrograma.

3.2. Interpretación

Los frames permiten dividir una señal larga en pequeñas “ventanas de observación”. Así:

- cada frame captura información local,
- la secuencia de frames permite seguir la evolución temporal,
- el análisis espectral de cada frame permite obtener una descripción tiempo–frecuencia.

4. Frame Size, Win Length y FFT Size

4.1. Frame Size

El término **frame size** suele referirse al número de muestras del segmento analizado en cada paso. Sin embargo, en la práctica puede confundirse con:

- la longitud de la ventana (`win_length`),
- el tamaño de la FFT (`n_fft`),
- el tamaño del bloque procesado.

Por claridad, conviene distinguir estos conceptos.

4.2. Win Length

La **longitud de ventana** L es el número de muestras que reciben ponderación no nula por la ventana $w[n]$. Controla directamente el compromiso entre resolución temporal y frecuencial.

- Ventana larga: mejor resolución en frecuencia, peor resolución temporal.
- Ventana corta: mejor resolución temporal, peor resolución en frecuencia.

4.3. n_{fft}

El tamaño de la FFT, denotado N , determina el número de bins de frecuencia calculados. Si $L < N$, el frame se completa con ceros antes de aplicar la FFT.

$$\Delta f = \frac{f_s}{N}$$

donde f_s es la frecuencia de muestreo.

4.4. Zero-padding

Cuando $N > L$, se aplica **zero-padding**. Esto:

- no agrega información nueva,
- no mejora la resolución real,
- sí produce una malla más densa de bins de frecuencia,
- puede suavizar visualmente el espectro.

5. Hop Size y Overlap

5.1. Hop Size

El **hop size** h es el número de muestras que separa el inicio de un frame del siguiente.

$$\Delta t = \frac{h}{f_s}$$

Esto determina la separación temporal entre columnas del espectrograma.

5.2. Interpretación

- Hop pequeño:
 - más columnas por segundo,
 - más solapamiento,
 - seguimiento temporal más fino,
 - mayor costo computacional.
- Hop grande:
 - menos columnas,
 - menor costo,
 - análisis más grueso temporalmente.

5.3. Overlap

El **overlap** es la proporción de solapamiento entre frames sucesivos:

$$\text{overlap} = 1 - \frac{h}{L}$$

Ejemplos:

- $h = L$: 0 % de overlap,
- $h = L/2$: 50 % de overlap,
- $h = L/4$: 75 % de overlap.

El overlap mejora la continuidad temporal del análisis y es muy importante para reconstrucción mediante *overlap-add*.

6. Windowing

6.1. Motivación

Si se toma un segmento de señal y se corta abruptamente, se introducen discontinuidades en los extremos. Esto produce **spectral leakage** o fuga espectral.

Multiplicar por una ventana suaviza los bordes del frame y reduce ese problema.

6.2. Idea matemática

El frame analizado es:

$$x_m[n] = x[n + mh] w[n]$$

Como la multiplicación en tiempo corresponde a convolución en frecuencia, la respuesta espectral final depende tanto de la señal como de la ventana.

6.3. Efecto del windowing

El uso de ventanas genera un compromiso entre:

- **ancho del lóbulo principal:** relacionado con la capacidad de distinguir tonos cercanos,
- **nivel de lóbulos laterales:** relacionado con la fuga espectral.

No existe una ventana óptima universal; su elección depende del objetivo.

7. Tipos de ventanas

7.1. Ventana rectangular

$$w[n] = 1, \quad 0 \leq n \leq L - 1$$

Ventajas:

- simplicidad,
- lóbulo principal relativamente angosto.

Desventajas:

- elevada fuga espectral,
- lóbulos laterales grandes.

7.2. Ventana Hann

$$w[n] = 0,5 - 0,5 \cos\left(\frac{2\pi n}{L-1}\right), \quad 0 \leq n \leq L-1$$

Características:

- extremos suaves,
- muy usada en STFT,
- buen compromiso entre resolución y fuga.

7.3. Ventana Hamming

Tiene forma parecida a la Hann, pero no cae exactamente a cero en los extremos. Suele reducir algunos lóbulos laterales respecto a la rectangular, con un compromiso algo distinto respecto a Hann.

7.4. Ventanas Blackman y familia

Suavizan más los extremos y reducen más los lóbulos laterales, pero ensanchan el lóbulo principal.

- Menor leakage.
- Peor resolución para separar tonos muy cercanos.

8. Resolución Tiempo–Frecuencia

8.1. Resolución en frecuencia

La separación entre bins de frecuencia es:

$$\Delta f = \frac{f_s}{N}$$

pero la **resolución real** depende más directamente de la duración efectiva del frame:

$$T_w = \frac{L}{f_s}$$

A mayor duración temporal del frame, mejor discriminación de frecuencias cercanas.

8.2. Resolución temporal

La resolución temporal depende del ancho de la ventana:

- ventana corta: mejor localización temporal,
- ventana larga: peor localización temporal.

8.3. Trade-off

Existe un compromiso intrínseco:

- si se mejora la resolución en frecuencia, se empeora la resolución temporal,
- si se mejora la resolución temporal, se empeora la resolución frecuencial.

Este trade-off es uno de los principios centrales de la STFT.

9. Magnitud, Potencia y Logaritmo

Dado el resultado complejo de la STFT:

$$X[k, m]$$

pueden definirse varias representaciones.

9.1. Espectrograma de magnitud

$$M[k, m] = |X[k, m]|$$

9.2. Espectrograma de potencia

$$P[k, m] = |X[k, m]|^2$$

9.3. Espectrograma logarítmico

$$S_{\text{dB}}[k, m] = 10 \log_{10}(P[k, m] + \varepsilon)$$

o, alternativamente,

$$S_{\text{dB}}[k, m] = 20 \log_{10}(M[k, m] + \varepsilon)$$

El uso de escala logarítmica es importante porque:

- el rango dinámico del audio es muy grande,
- la percepción auditiva humana es aproximadamente logarítmica.

10. Interpretación del Espectrograma

Cada píxel del espectrograma no representa una frecuencia exacta en un instante exacto, sino:

la energía local de una banda de frecuencia, estimada en una vecindad temporal determinada por la ventana.

Por tanto, el espectrograma debe interpretarse como una representación local y suavizada del contenido frecuencial.

11. Reconstrucción e ISTFT

La STFT puede invertirse aproximadamente o incluso casi perfectamente si:

- se conserva la fase,

- se usan parámetros consistentes entre STFT e ISTFT,
- la combinación ventana + hop cumple condiciones adecuadas.

La reconstrucción suele basarse en el método de **overlap-add**. Condiciones como COLA (*Constant OverLap Add*) o NOLA son relevantes para garantizar reconstrucción estable.

12. Escala Mel

12.1. Definición

La **escala Mel** es una transformación no lineal de la frecuencia diseñada para aproximar la percepción humana del tono.

Una fórmula clásica es:

$$m = 2595 \log_{10} \left(1 + \frac{f}{700} \right)$$

donde:

- f está en Hz,
- m está en Mels.

La inversa es:

$$f = 700 \left(10^{m/2595} - 1 \right)$$

12.2. Interpretación

La escala Mel es:

- aproximadamente lineal a bajas frecuencias,
- aproximadamente logarítmica a frecuencias medias y altas.

Esto refleja que el oído distingue con mayor finura diferencias pequeñas en frecuencias bajas que en frecuencias altas.

13. Banco de Filtros Mel

13.1. Idea general

Un **banco de filtros Mel** es un conjunto de filtros, normalmente triangulares, definidos sobre el eje de frecuencia lineal de la STFT. Su propósito es agrupar la energía espectral en bandas perceptuales.

13.2. Construcción

El procedimiento conceptual es:

1. elegir un rango de frecuencias $[f_{\min}, f_{\max}]$,
2. repartir puntos equiespaciados en la escala Mel,
3. convertir esos puntos a Hz,
4. construir filtros triangulares usando esos puntos como centros y extremos.

13.3. Filtro triangular típico

Si los puntos de quiebre de un filtro son f_{b-1}, f_b, f_{b+1} , entonces:

$$H_b(f) = \begin{cases} 0, & f < f_{b-1} \\ \frac{f - f_{b-1}}{f_b - f_{b-1}}, & f_{b-1} \leq f \leq f_b \\ \frac{f_{b+1} - f}{f_{b+1} - f_b}, & f_b \leq f \leq f_{b+1} \\ 0, & f > f_{b+1} \end{cases}$$

13.4. Interpretación

Cada filtro:

- captura energía de una banda específica,
- da más peso a la frecuencia central,
- se solapa con filtros vecinos,
- actúa como una agregación local del espectro lineal.

14. Mel-Espectrograma

14.1. Definición

El **mel-espectrograma** se obtiene aplicando el banco de filtros Mel al espectrograma lineal. Si:

$$S[k, m] = |X[k, m]|^\alpha$$

es el espectrograma base, entonces:

$$M[b, m] = \sum_{k=0}^{K-1} H[b, k] S[k, m]$$

donde:

- k indexa bins lineales de la STFT,
- b indexa filtros Mel,
- $H[b, k]$ es el banco de filtros,
- $M[b, m]$ es el mel-espectrograma.

14.2. Forma matricial

Si:

$$S \in \mathbb{R}_{\geq 0}^{K \times T}$$

y

$$H \in \mathbb{R}_{\geq 0}^{B \times K}$$

entonces:

$$M = HS$$

donde:

$$M \in \mathbb{R}_{\geq 0}^{B \times T}$$

Esto muestra que el mel-espectrograma es una **proyección lineal** del espectrograma lineal hacia un espacio de bandas perceptuales.

15. Qué gana y qué pierde el Mel-Espectrograma

15.1. Ventajas

- representación más compacta,
- mejor alineación con la percepción auditiva,
- mayor robustez para muchas tareas de voz,
- reducción de dimensionalidad,
- suavizado espectral útil para aprendizaje automático.

15.2. Desventajas

- pérdida de detalle fino en frecuencia,
- menor interpretabilidad exacta en Hz,
- no es estrictamente invertible,
- mezcla información de varios bins lineales.

16. Relación entre Espectrograma y Mel-Espectrograma

Todo lo discutido para STFT sigue siendo válido en el mel-espectrograma:

- sigue usando **frames**,
- sigue dependiendo de **frame size**,
- sigue usando **hop size**,
- sigue dependiendo del **windowing**,
- parte de una STFT o de un espectrograma lineal.

La diferencia es que, después del análisis espectral lineal, se aplica una transformación frecuencial perceptual.

17. Parámetros Fundamentales del Mel-Espectrograma

17.1. n_{mels}

Es el número de bandas Mel.

- Mayor n_{mels} : más detalle vertical, menos compresión.
- Menor n_{mels} : más compresión, menos detalle.

17.2. $f_{\text{mín}}$ y $f_{\text{máx}}$

Definen el rango de frecuencias cubierto por el banco Mel:

$$f \in [f_{\text{mín}}, f_{\text{máx}}]$$

Modificar estos valores cambia:

- qué parte del espectro se conserva,
- cómo se distribuyen las bandas Mel.

17.3. Power

El mel-espectrograma suele construirse a partir de magnitud o potencia:

$$S[k, m] = |X[k, m]|^\alpha$$

con $\alpha = 2$ como elección habitual para potencia.

17.4. Compresión logarítmica

Frecuentemente se usa:

$$M_{\text{dB}}[b, m] = 10 \log_{10}(M[b, m] + \varepsilon)$$

Esto mejora la visualización y hace la representación más compatible con percepción auditiva y con sistemas de reconocimiento.

18. Interpretación del Mel-Espectrograma

Cada píxel (b, m) representa:

la energía de la señal alrededor del tiempo m , dentro de la banda perceptual Mel b .

No representa una frecuencia puntual exacta, sino una banda perceptual obtenida como combinación ponderada de bins lineales.

19. Resumen Comparativo

Concepto	Espectrograma lineal	Mel-espectrograma
Eje de frecuencia	Lineal en Hz	Perceptual en Mels
Base matemática	STFT	Banco Mel aplicado a STFT
Resolución alta en Hz	Sí	No necesariamente
Compresión perceptual	No	Sí
Detalle fino de armónicos	Mayor	Menor
Utilidad en voz/ML	Alta	Muy alta
Invertibilidad	Mejor	Peor / aproximada
Dimensionalidad	Mayor	Menor