

MFCCs para Speaker Recognition Forense

1. Introducción

En esta clase estudiamos de manera detallada los **MFCCs** (*Mel-Frequency Cepstral Coefficients*), una de las representaciones más importantes en procesamiento de voz y, en particular, en **speaker recognition** y **voz forense**. La idea central fue entender que los MFCCs no son solo una técnica computacional, sino el resultado de una cadena de conceptos físicos, acústicos y matemáticos que conectan:

- la **producción de la voz**,
- el **análisis espectral**,
- la **percepción auditiva**,
- y la **representación compacta** de información relevante del hablante.

El objetivo principal de los MFCCs es describir de forma compacta la **envolvente espectral** de la voz, que está estrechamente relacionada con el **tracto vocal**, y por lo tanto con características útiles para distinguir hablantes.

2. ¿Qué son los MFCCs?

Los MFCCs son coeficientes que resumen la forma global del espectro de una señal de voz en ventanas cortas de tiempo. Se construyen a partir de:

1. la señal de voz en el dominio del tiempo,
2. su representación en frecuencia mediante la DFT,
3. un banco de filtros en escala Mel,
4. el logaritmo de las energías espectrales,
5. y finalmente una DCT.

La razón por la cual los MFCCs son tan útiles es que capturan principalmente información asociada al **filtro del tracto vocal**, reduciendo en cierta medida detalles finos menos útiles, como la estructura armónica exacta de la excitación.

3. Modelo fuente-filtro de la voz

Una parte fundamental de la clase fue comprender la voz a partir del **modelo fuente-filtro**. Según este modelo, la voz puede representarse como la convolución entre una fuente de excitación y el tracto vocal:

$$s[n] = e[n] * h[n]$$

donde:

- $s[n]$ es la señal de voz,
- $e[n]$ es la excitación o fuente,
- $h[n]$ es la respuesta impulsional del tracto vocal.

3.1. Pulso glotal

La fuente de excitación en sonidos voceados proviene de la vibración de las cuerdas vocales. Esa excitación periódica se conoce como **pulso glotal**. El pulso glotal genera una estructura periódica que, en frecuencia, produce armónicos.

3.2. Tracto vocal

El **tracto vocal** actúa como un filtro resonante. Está formado por la faringe, cavidad oral y, en algunos casos, la cavidad nasal. La configuración del tracto vocal cambia según la articulación y modifica el contenido espectral de la voz.

3.3. Formantes

Los **formantes** son las resonancias principales del tracto vocal. En el espectro aparecen como regiones de alta energía o picos amplios. Los formantes reflejan la configuración del sistema articulatorio y son muy importantes porque influyen directamente en la envolvente espectral.

4. Transformada de Fourier (DFT)

Para estudiar el contenido frecuencial de la voz usamos la **Transformada Discreta de Fourier (DFT)**. Para un frame $x[n]$ de longitud N , la DFT se define como:

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi kn/N}, \quad k = 0, \dots, N-1$$

donde:

- $x[n]$ es la señal en el tiempo,

- $X[k]$ es la representación compleja en frecuencia,
- N es el número de muestras del frame.

La DFT nos permite conocer qué frecuencias están presentes en la señal y con qué intensidad. En procesamiento de voz, normalmente se analiza la **magnitud** o la **potencia** del espectro, más que la fase.

5. Log Amplitude Spectrum

Una vez que calculamos la DFT, obtenemos el espectro de magnitud $|X[k]|$ o el espectro de potencia $|X[k]|^2$. Después se aplica un logaritmo para construir el **espectro de amplitud logarítmica** o una variante equivalente:

$$\log |X[k]| \quad \text{o} \quad \log |X[k]|^2$$

Tomar el logaritmo es importante por tres razones principales:

1. **Compresión del rango dinámico:** reduce grandes diferencias de amplitud.
2. **Aproximación perceptual:** el sistema auditivo percibe intensidades de forma aproximadamente logarítmica.
3. **Separación fuente-filtro:** convierte productos en sumas.

Si en frecuencia tenemos:

$$S(\omega) = E(\omega)H(\omega)$$

entonces:

$$\log |S(\omega)| = \log |E(\omega)| + \log |H(\omega)|$$

Esta propiedad es la base del análisis cepstral.

6. Armónicos, envolvente espectral y relación con la voz

En el espectro de una señal de voz voceada aparecen dos componentes conceptualmente distintas:

6.1. Armónicos

Los **armónicos** son múltiplos enteros de la frecuencia fundamental f_0 :

$$f_k = k f_0, \quad k = 1, 2, 3, \dots$$

Estos surgen debido a la periodicidad del pulso glotal.

6.2. Envolverte espectral

La **envolverte espectral** es la curva suave que pasa por encima de los picos armónicos y describe la distribución global de energía en frecuencia. Esta envolverte está asociada principalmente al **tracto vocal** y sus **formantes**.

Los MFCCs están diseñados precisamente para capturar esta envolverte espectral, más que la estructura armónica fina.

7. Mel Spectrogram (Espectrograma Mel)

El **espectrograma Mel** es una representación tiempo-frecuencia basada en la escala Mel, que aproxima la forma en que el oído humano percibe diferencias de frecuencia.

7.1. Escala Mel

La relación entre frecuencia en Hz y frecuencia en Mels se expresa comúnmente como:

$$m = 2595 \log_{10} \left(1 + \frac{f}{700} \right)$$

y su inversa es:

$$f = 700 \left(10^{m/2595} - 1 \right)$$

Esta escala es aproximadamente lineal a bajas frecuencias y logarítmica a frecuencias altas.

7.2. Banco de filtros Mel

En vez de usar directamente todos los bins de la FFT, se emplea un **banco de filtros triangulares** distribuidos uniformemente en la escala Mel. Si $P[k]$ es el espectro de potencia y $H_m[k]$ es el filtro Mel número m , entonces la energía en la banda m es:

$$E_m = \sum_{k=0}^{N-1} P[k] H_m[k]$$

Esto permite obtener una descripción suavizada del espectro, agrupando energía en bandas perceptualmente relevantes.

7.3. Importancia del espectrograma Mel

El espectrograma Mel:

- reduce la resolución excesiva donde no hace falta,
- modela mejor la percepción auditiva,
- suaviza detalles finos,

- y prepara la información para el cálculo de los MFCCs.

8. Cepstrum (Cepstro)

El **cepstro** es una representación obtenida al aplicar una transformada al logaritmo del espectro. Una forma clásica de definirlo es:

$$c[n] = \mathcal{F}^{-1}\{\log |X(\omega)|\}$$

o, en forma discreta:

$$c[q] = \frac{1}{N} \sum_{k=0}^{N-1} \log |X[k]| e^{j2\pi kq/N}$$

El cepstro es útil porque ayuda a separar dos tipos de estructura del espectro:

- la parte **suave**, asociada a la envolvente espectral y al tracto vocal,
- la parte **rápidamente oscilatoria**, asociada a la periodicidad de la excitación y a los armónicos.

En otras palabras, el cepstro facilita una separación parcial entre **fuentes** y **filtros**.

9. Quefreny (Quifreny)

La **quifreny** es el eje del dominio cepstral. Aunque su nombre surge como un juego de palabras, conceptualmente sirve para interpretar diferentes escalas de variación del log-espectro.

- **Bajas quifrencias**: representan variaciones lentas del espectro, es decir, la envolvente.
- **Altas quifrencias**: representan oscilaciones rápidas, como las asociadas al espaciado armónico.

En voz, esto significa que la información del tracto vocal suele concentrarse en bajas quifrencias, mientras que la periodicidad glotal puede reflejarse en quifrencias relacionadas con el periodo fundamental:

$$T_0 = \frac{1}{f_0}$$

10. Harmonics y Ramonics

10.1. Harmonics

Los **harmonics** o armónicos aparecen en el dominio de la frecuencia como múltiplos enteros de f_0 . Son consecuencia de la periodicidad de la señal de excitación.

10.2. Ramonics

En el dominio cepstral, la periodicidad armónica en frecuencia se manifiesta como una estructura localizada cerca de la quifrencia correspondiente al periodo fundamental. A esta manifestación se le suele llamar informalmente **rahmonics** o **ramonics**.

La intuición es:

- los armónicos son una repetición en frecuencia,
- los ramónicos son la huella de esa repetición en el dominio cepstral.

Este punto es importante porque ayuda a entender por qué el cepstro puede separar información de pitch y de envolvente espectral.

11. Liftering (Liftrado)

El **liftering** es el equivalente del filtrado, pero aplicado en el dominio cepstral. Si $c[n]$ son los coeficientes cepstrales y $L[n]$ es el lifter, entonces:

$$\tilde{c}[n] = L[n]c[n]$$

El liftering permite:

- resaltar ciertas regiones de quifrencia,
- suprimir componentes no deseadas,
- mejorar robustez,
- concentrarse en la envolvente o, alternativamente, en la estructura periódica.

Dos ideas importantes son:

- **Low-time liftering**: enfatiza bajas quifrencias, es decir, la envolvente espectral.
- **High-time liftering**: enfatiza altas quifrencias, asociadas a detalles finos o periodicidad.

En el contexto de MFCCs, suele interesar principalmente la información de **baja quifrencia**.

12. Discrete Cosine Transform (DCT)

Después de obtener las energías Mel y aplicar el logaritmo, se aplica una **Transformada Discreta del Coseno (DCT)** para convertir esa información en coeficientes compactos:

$$c_n = \sum_{m=1}^M \log E_m \cos \left[\frac{\pi n}{M} (m - 1/2) \right], \quad n = 0, 1, \dots, M - 1$$

donde:

- M es el número de filtros Mel,
- E_m es la energía del filtro Mel m ,
- c_n es el coeficiente cepstral n .

La DCT es importante porque:

1. **compacta energía**,
2. **reduce correlación** entre coeficientes,
3. **resume la forma global** del log-espectro Mel.

Los primeros coeficientes suelen contener la información más relevante sobre la envolvente espectral.

13. Cálculo completo de los MFCCs

El procedimiento completo para calcular los MFCCs puede resumirse así:

1. Segmentación en frames

Se divide la señal en ventanas cortas, típicamente de 20 a 25 ms.

2. Ventaneado

Se aplica una ventana, por ejemplo Hamming:

$$x_w[n] = x[n]w[n]$$

3. DFT

Se calcula el espectro:

$$X[k] = \sum_{n=0}^{N-1} x_w[n] e^{-j2\pi kn/N}$$

4. Espectro de potencia

Se obtiene:

$$P[k] = \frac{1}{N} |X[k]|^2$$

5. Banco de filtros Mel

Se calcula la energía en cada banda:

$$E_m = \sum_{k=0}^{N-1} P[k] H_m[k]$$

6. Logaritmo

Se aplica:

$$L_m = \log E_m$$

7. DCT

Finalmente:

$$c_n = \sum_{m=1}^M L_m \cos \left[\frac{\pi n}{M} (m - 1/2) \right]$$

Los c_n resultantes son los **MFCCs**.

14. Delta y Delta-Delta MFCCs

Además de los MFCCs estáticos, se introducen características dinámicas para capturar cómo cambia la voz en el tiempo.

14.1. Delta

Los **delta MFCCs** son una aproximación de la primera derivada temporal:

$$\Delta c_t = \frac{\sum_{n=1}^N n(c_{t+n} - c_{t-n})}{2 \sum_{n=1}^N n^2}$$

Reflejan la velocidad de cambio de los coeficientes.

14.2. Delta-Delta

Los **delta-delta MFCCs** representan la segunda derivada temporal:

$$\Delta^2 c_t = \frac{\sum_{n=1}^N n(\Delta c_{t+n} - \Delta c_{t-n})}{2 \sum_{n=1}^N n^2}$$

Reflejan la aceleración o curvatura del cambio temporal.

14.3. Interpretación

- MFCC estático: describe la forma espectral del frame actual.
- Delta: describe cómo cambia esa forma.
- Delta-delta: describe cómo cambia el cambio.

En muchos sistemas clásicos se usan conjuntamente, formando vectores de 39 características: 13 estáticas, 13 delta y 13 delta-delta.

15. Importancia de los MFCCs en voz forense y speaker recognition

Los MFCCs son especialmente valiosos en reconocimiento de locutor porque capturan información muy relacionada con la anatomía y la articulación del hablante, sobre todo la forma del tracto vocal. Esto los hace útiles para modelar identidad vocal.

Entre sus ventajas están:

- representación compacta,
- buena capacidad descriptiva,
- relación con la envolvente espectral,
- compatibilidad con modelos estadísticos y de aprendizaje.

Sin embargo, también vimos que tienen limitaciones:

- son sensibles al ruido y al canal,
- pueden perder detalle fino útil,
- no representan explícitamente la fase,
- dependen de parámetros del sistema de extracción.

Por eso, aunque siguen siendo fundamentales, en sistemas modernos también se usan otras representaciones como log-Mel filterbanks o embeddings aprendidos.

16. Idea central de toda la clase

La idea más importante de la clase fue que los MFCCs intentan describir, de manera compacta, la **envolvente espectral** de la voz, que está muy ligada al **tracto vocal**, mientras reducen parcialmente el detalle fino asociado a la **excitación glotal**. Para lograrlo, combinan:

- análisis en frecuencia,
- compresión logarítmica,
- representación perceptual en escala Mel,
- y compactación mediante DCT.

En resumen, los MFCCs pueden entenderse como una representación que busca conservar lo más útil del espectro para identificar al hablante, eliminando redundancia y enfatizando características relacionadas con la estructura resonante de la voz.