

Features y embeddings (Speaker Recognition en Voz Forense)

Índice

1. Features modernas y su papel en speaker recognition	3
2. Log-Mel filterbanks	3
2.1. Definición	3
2.2. Pipeline detallado	4
2.3. Ventajas	4
3. Diferencia entre espectrograma, Mel spectrograma, log-Mel filterbanks y MFCC	4
3.1. Espectrograma	5
3.2. Mel spectrograma	5
3.3. Log-Mel filterbanks	5
3.4. MFCC	5
3.5. Resumen comparativo	6
4. VAD (Voice Activity Detection)	6
4.1. Definición	6
4.2. Por qué importa	6
4.3. Pipeline general	7
4.4. Tipos principales	7
4.5. Importancia forense	7
4.6. VAD vs diarization	7
5. CMVN (Cepstral Mean and Variance Normalization)	7
5.1. Definición	7
5.2. Operaciones principales	8
5.3. Qué problema intenta resolver	8
5.4. Tipos de CMVN	8
5.5. Relación con VAD	9
5.6. Papel en speaker recognition	9

6. Augmentation	9
6.1. Definición	9
6.2. Objetivo principal	9
6.3. Tipos de augmentation estudiados	10
6.4. Precaución	10
7. x-vectors internamente	10
7.1. Definición	10
7.2. Idea central	10
7.3. Pipeline general	10
7.4. TDNN	11
7.5. Stats Pooling	11
7.6. Importancia histórica	11
7.7. Limitaciones	11
8. ECAPA-TDNN internamente	12
8.1. Definición	12
8.2. Idea general	12
8.3. Pipeline conceptual	12
8.4. Res2Net / Res2Blocks	12
8.5. SE Blocks	12
8.6. Residual connections	13
8.7. Attentive Statistics Pooling	13
8.8. Por qué supera a x-vector	13
8.9. Importancia forense	13
9. SSL Embeddings	13
9.1. Definición	13
9.2. Cambio de paradigma	14
9.3. Pipeline general	14
9.4. Modelos mencionados	14
9.5. Ventaja clave	14
9.6. Modos de uso	14
9.7. Relación con ECAPA	14
10. Embeddings en Speaker Recognition Forense	15
10.1. Qué son los embeddings	15
10.2. Espacio vectorial y similitud entre locutores	15
10.3. Información que capturan	15
10.4. Embeddings clásicos y modernos	15
10.5. Limitaciones forenses de los embeddings	15
11. Comparación entre Feature y Embedding	16

1. Features modernas y su papel en speaker recognition

El reconocimiento moderno de hablantes se apoya en **features acústicas** que representan la señal de voz de forma útil para que un modelo pueda extraer patrones relacionados con la identidad del locutor. Una buena feature debe capturar:

- características anatómicas del tracto vocal,
- patrones articulatorios y espectrales,
- información temporal,
- robustez ante canal, ruido y micrófono,
- y suficiente detalle para que una red profunda pueda aprender representaciones discriminativas.

Las features modernas no buscan necesariamente una representación “perfecta” del hablante, sino una base rica sobre la que el modelo pueda aprender. Entre las más utilizadas actualmente destacan:

- **Log-Mel filterbanks**,
- **VAD**,
- **CMVN**,
- augmentations sobre audio o features,
- embeddings derivados de modelos SSL.

En la práctica, los sistemas modernos como **x-vector** y **ECAPA-TDNN** suelen basarse en **log-Mel filterbanks** como entrada principal, con apoyo de **VAD** y **CMVN** como parte del preprocesamiento.

2. Log-Mel filterbanks

2.1. Definición

Los log-Mel filterbanks son una representación tiempo-frecuencia basada en:

1. el análisis de corto plazo de la señal,
2. el cálculo del espectro por frame,
3. la agregación de energía en bandas Mel,
4. y la aplicación de un logaritmo a dichas energías.

El resultado es una matriz de tamaño:

$$\text{frames} \times \text{bandas Mel}$$

Por ejemplo, una configuración común es:

$$\text{frames} \times 80$$

2.2. Pipeline detallado

1. Señal de entrada $x[n]$
2. Framing (por ejemplo, 25 ms)
3. Windowing (por ejemplo, Hamming)
4. FFT
5. Cálculo de potencia espectral
6. Banco de filtros Mel
7. Energía por banda
8. Logaritmo

Formalmente, si E_i es la energía de la banda Mel i , la feature final usa algo como:

$$\log(E_i + \epsilon)$$

2.3. Ventajas

- Conservan más detalle espectral que MFCC.
- Son adecuadas para modelos profundos.
- Se comportan como una “imagen” tiempo-frecuencia.
- Son estándar en sistemas modernos.

3. Diferencia entre espectrograma, Mel spectrograma, log-Mel filterbanks y MFCC

Antes de seguir con los siguientes features considero importante hacer una pausa para lograr entender cuáles son las diferencias entre los espectrogramas, los mel-espectrogramas, los MFCC y los log-mel filterbanks; ya que en sus definiciones y pipelines de cálculo tienen conceptos estrechamente relacionados.

3.1. Espectrograma

El espectrograma muestra cómo evoluciona la energía en frecuencia con el tiempo. Sus ejes son:

- eje horizontal: tiempo,
- eje vertical: frecuencia lineal (Hz),
- intensidad/color: magnitud o potencia.

Pipeline del espectrograma

Audio $\rightarrow$ Framing $\rightarrow$ Windowing $\rightarrow$ FFT $\rightarrow$ Magnitud/Potencia

Es una representación rica, pero no perceptualmente organizada y suele tener demasiadas dimensiones para muchos modelos clásicos.

3.2. Mel spectrograma

El Mel spectrograma toma el espectrograma y reemplaza la frecuencia lineal por una frecuencia distribuida según la **escala Mel**, que aproxima mejor la percepción auditiva humana.

Pipeline del Mel spectrograma

Audio $\rightarrow$ Framing $\rightarrow$ Windowing $\rightarrow$ FFT $\rightarrow$ Potencia $\rightarrow$ Banco Mel

Aquí la energía se agrupa en bandas perceptuales.

3.3. Log-Mel filterbanks

Los log-Mel filterbanks son esencialmente un **Mel spectrograma al que se le aplica logaritmo**. En muchos contextos, los términos *FBANK*, *Mel filterbanks* y *log-Mel filterbanks* se usan casi como equivalentes, aunque técnicamente el logaritmo es una etapa extra.

Pipeline de log-Mel filterbanks

Audio $\rightarrow$ Framing $\rightarrow$ Windowing $\rightarrow$ FFT $\rightarrow$ Potencia $\rightarrow$ Banco Mel $\rightarrow$ $\log(\cdot)$

Esta representación es hoy una de las más importantes para redes profundas en voz.

3.4. MFCC

Los MFCC (*Mel-Frequency Cepstral Coefficients*) parten de las energías log-Mel y luego aplican una DCT (*Discrete Cosine Transform*) para obtener una representación más compacta y decorrelacionada.

Pipeline de MFCC

Audio $\rightarrow$ Framing $\rightarrow$ Windowing $\rightarrow$ FFT $\rightarrow$ Potencia $\rightarrow$ Banco Mel $\rightarrow$ $\log(\cdot)$ $\rightarrow$ DCT

3.5. Resumen comparativo

Representación	Frecuencia	Transformación adicional	Uso típico
Espectrograma	Lineal	Ninguna relevante después de FFT	Análisis general
Mel spectrograma	Escala Mel	Banco de filtros Mel	Audio deep learning
Log-Mel filterbanks	Escala Mel	Logaritmo de energías Mel	Speaker recognition moderno
MFCC	Escala Mel interna	Logaritmo + DCT	Sistemas clásicos

La relación jerárquica completa es:

Waveform $\rightarrow$ Espectrograma $\rightarrow$ Mel Spectrograma $\rightarrow$ Log-Mel $\rightarrow$ MFCC

4. VAD (Voice Activity Detection)

4.1. Definición

VAD es el proceso de decidir qué partes del audio contienen **voz** y cuáles no. Su objetivo es filtrar:

- silencios,
- ruido ambiente,
- respiraciones,
- artefactos,
- pausas no informativas.

4.2. Por qué importa

En speaker recognition, si un embedding se calcula usando muchos frames sin voz, se contamina con información irrelevante. En vez de resumir la voz del hablante, empieza a resumir una mezcla de:

- voz,

- silencio,
- ruido,
- canal.

4.3. Pipeline general

Audio → VAD → Frames de voz → Features → Modelo

4.4. Tipos principales

- **Energy-based VAD**: usa energía para decidir si hay voz.
- **VAD basado en energía + cruces por cero**.
- **VAD estadístico**: modela voz y ruido probabilísticamente.
- **WebRTC VAD**: muy usado en práctica e industria.
- **Neural VAD**: usa redes neuronales para estimar probabilidad de voz.

4.5. Importancia forense

Un VAD demasiado agresivo puede eliminar voz útil. Uno demasiado laxo puede introducir demasiado ruido. Por tanto, debe balancear:

- **recall**: no perder voz,
- **precision**: no incluir no-voz.

4.6. VAD vs diarization

Se distinguió claramente:

- **VAD**: responde si hay voz o no.
- **Diarization**: responde quién habla y cuándo.

5. CMVN (Cepstral Mean and Variance Normalization)

5.1. Definición

CMVN es una técnica de normalización aplicada a las features acústicas. Busca que cada dimensión tenga aproximadamente:

$$\mu = 0, \quad \sigma^2 = 1$$

5.2. Operaciones principales

Dada una secuencia de valores $x_1, x_2, \dots, x_T$:

Mean normalization

$$\mu = \frac{1}{T} \sum_{t=1}^T x_t$$
$$x'_t = x_t - \mu$$

Variance normalization

$$\sigma = \sqrt{\frac{1}{T} \sum_{t=1}^T (x_t - \mu)^2}$$
$$z_t = \frac{x_t - \mu}{\sigma}$$

5.3. Qué problema intenta resolver

Las features contienen no solo información del hablante, sino también:

- nivel de señal,
- ganancia,
- canal,
- micrófono,
- respuesta en frecuencia,
- condiciones estables de grabación.

CMVN reduce esas diferencias estadísticas globales.

5.4. Tipos de CMVN

- **Per-utterance CMVN**: calculado por archivo.
- **Sliding-window CMVN**: con ventana deslizante.
- **Global CMVN**: con estadísticas globales del conjunto de entrenamiento.

5.5. Relación con VAD

Se destacó que CMVN funciona mejor cuando se calcula sobre frames de voz seleccionados por VAD. Si se incluye demasiado silencio o ruido, la media y varianza quedan contaminadas.

5.6. Papel en speaker recognition

- Muy común en sistemas clásicos basados en MFCC.
- Sigue siendo relevante en x-vector.
- En ECAPA puede aparecer como mean normalization o variantes equivalentes.

6. Augmentation

6.1. Definición

Data augmentation consiste en generar variantes perturbadas del audio de entrenamiento para que el modelo aprenda a ser robusto a condiciones del mundo real.

6.2. Objetivo principal

El modelo debe aprender que cambios en:

- ruido,
- reverberación,
- codec,
- canal,
- volumen,
- velocidad,

no implican necesariamente un cambio en la identidad del hablante.

Formalmente, si x es un audio y $T(x)$ su versión aumentada, idealmente queremos que:

$$f(x) \approx f(T(x))$$

donde $f(\cdot)$ representa el embedding del hablante.

6.3. Tipos de augmentation estudiados

- **Additive noise**: agregar ruido externo.
- **Reverberación con RIR**: convolución con una respuesta al impulso de sala.
- **Speed perturbation**: cambiar ligeramente la velocidad.
- **Volume perturbation**: modificar ganancia.
- **Codec/compression augmentation**: simular compresión o telefonía.
- **Bandwidth limitation**: simular narrowband.
- **Random cropping**: usar fragmentos aleatorios del audio.
- **SpecAugment**: enmascaramiento sobre features tiempo-frecuencia.

6.4. Precaución

No todo augmentation es útil. Si la perturbación destruye excesivamente la identidad del hablante, perjudica el aprendizaje. La regla correcta es:

Perturbar sin destruir identidad.

7. x-vectors internamente

7.1. Definición

Un x-vector es un **embedding fijo** de hablante extraído a partir de un audio de longitud variable. Resume la identidad del hablante en un vector de dimensión fija.

7.2. Idea central

Durante entrenamiento, una red se entrena para clasificar miles de hablantes. Una capa interna aprende una representación discriminativa útil; esa representación se extrae como embedding.

7.3. Pipeline general

Audio $\rightarrow$ VAD $\rightarrow$ MFCC/log-Mel $\rightarrow$ TDNN frame-level $\rightarrow$ Stats Pooling $\rightarrow$ Capas segment-level

$\rightarrow$ Softmax

En inferencia:

Audio $\rightarrow$ Red $\rightarrow$ x-vector

7.4. TDNN

La red base del x-vector es una **Time Delay Neural Network**, que procesa contexto temporal local. Por ejemplo, para un frame t , una capa puede usar:

$$[t - 2, t - 1, t, t + 1, t + 2]$$

Esto permite capturar información temporal de corto y mediano alcance.

7.5. Stats Pooling

El componente más importante del x-vector fue el **Stats Pooling**, que permite convertir una secuencia variable de frames en un vector fijo.

Dada una secuencia $h_1, h_2, \dots, h_T$, se calcula:

$$\mu = \frac{1}{T} \sum h_t$$

$$\sigma = \sqrt{\frac{1}{T} \sum (h_t - \mu)^2}$$

y luego se concatena:

$$[\mu; \sigma]$$

Esto resume tanto el comportamiento promedio como la dispersión temporal.

7.6. Importancia histórica

El x-vector marcó el paso de sistemas clásicos como i-vector a un paradigma deep learning discriminativo. Sus fortalezas principales fueron:

- mejor uso de grandes cantidades de datos,
- embeddings aprendidos directamente,
- mejor discriminación entre hablantes.

7.7. Limitaciones

- pooling uniforme: todos los frames pesan igual,
- capacidad limitada frente a arquitecturas más recientes,
- menos refinamiento atencional que modelos posteriores.

8. ECAPA-TDNN internamente

8.1. Definición

ECAPA-TDNN es una evolución moderna del x-vector. Su nombre proviene de:

Emphasized Channel Attention, Propagation and Aggregation in TDNN

8.2. Idea general

ECAPA conserva la lógica de:

features $\rightarrow$ red temporal $\rightarrow$ pooling $\rightarrow$ embedding

pero mejora el proceso incorporando:

- contexto multi-escala,
- atención por canales,
- conexiones residuales,
- mejor agregación de capas,
- attentive statistics pooling.

8.3. Pipeline conceptual

Audio $\rightarrow$ VAD $\rightarrow$ log-Mel $\rightarrow$ ECAPA blocks $\rightarrow$ Attentive Stats Pooling $\rightarrow$ Embedding

8.4. Res2Net / Res2Blocks

ECAPA introduce bloques que dividen los canales internos en grupos, permitiendo modelar contexto temporal a distintas escalas. Esto mejora la captura de patrones:

- cortos,
- medios,
- más amplios.

8.5. SE Blocks

Los bloques **Squeeze-and-Excitation** permiten ponderar canales internos según su relevancia. La red aprende qué canales son más útiles para distinguir hablantes.

8.6. Residual connections

Las conexiones residuales ayudan a entrenar redes más profundas y estables.

8.7. Attentive Statistics Pooling

A diferencia del x-vector clásico, ECAPA no trata todos los frames por igual. Introduce pesos α_t aprendidos:

$$\mu = \sum_t \alpha_t h_t \quad \text{con} \quad \sum_t \alpha_t = 1$$

Esto permite que frames más informativos tengan mayor impacto en el embedding final.

8.8. Por qué supera a x-vector

ECAPA mejora x-vector porque:

- ve contexto temporal a múltiples escalas,
- prioriza información útil mediante atención,
- usa pooling más inteligente,
- genera embeddings más discriminativos.

8.9. Importancia forense

ECAPA es uno de los modelos más fuertes en la práctica moderna y suele ser una referencia muy seria para aplicaciones reales. Sin embargo, no resuelve por sí solo problemas como:

- solapamiento de voces,
- clips ultracortos,
- spoofing sofisticado,
- mismatch extremo de dominio.

9. SSL Embeddings

9.1. Definición

SSL significa **Self-Supervised Learning**. La idea no es aprender directamente desde etiquetas humanas masivas, sino usar tareas de entrenamiento generadas a partir del propio audio.

9.2. Cambio de paradigma

En vez de depender únicamente de datos etiquetados con identidad de hablante, los modelos SSL se preentrenan con enormes cantidades de audio sin etiquetar. Luego se adaptan a tareas como speaker recognition.

9.3. Pipeline general

Audio crudo $\rightarrow$ SSL encoder preentrenado $\rightarrow$ Representaciones profundas $\rightarrow$
Pooling / Head $\rightarrow$ Embedding speaker

9.4. Modelos mencionados

Se estudiaron como referencias conceptuales:

- wav2vec 2.0
- HuBERT
- WavLM

9.5. Ventaja clave

Los modelos SSL aprenden regularidades muy generales del habla:

- variaciones fonéticas,
- parte de la información del hablante,
- robustez ante diversas condiciones.

9.6. Modos de uso

- **Frozen encoder:** se congela el encoder y se extraen embeddings.
- **Fine-tuning completo:** se adapta todo el modelo a speaker recognition.
- **SSL + speaker head:** se coloca una cabeza de clasificación/pooling encima.

9.7. Relación con ECAPA

En muchos sistemas modernos, SSL y ECAPA no son excluyentes. Puede usarse:

Audio $\rightarrow$ SSL encoder $\rightarrow$ Head tipo ECAPA $\rightarrow$ Embedding

10. Embeddings en Speaker Recognition Forense

10.1. Qué son los embeddings

Un embedding es una representación numérica compacta de una muestra de voz en forma de vector de dimensión fija. Su propósito es resumir información relevante del hablante en un espacio matemático apto para comparación automática.

10.2. Espacio vectorial y similitud entre locutores

Cada muestra de voz queda representada como un punto en un espacio multidimensional. Grabaciones del mismo hablante tienden a ubicarse cercanas entre sí, mientras que grabaciones de hablantes distintos suelen aparecer más alejadas.

10.3. Información que capturan

Los embeddings buscan conservar rasgos relativamente estables del locutor, como timbre, configuración del tracto vocal, patrones articulatorios y ciertos aspectos prosódicos.

Intentan reducir la influencia de ruido ambiental, tipo de micrófono, compresión, canal telefónico, idioma, contenido lingüístico y variaciones emocionales momentáneas.

10.4. Embeddings clásicos y modernos

Entre los enfoques clásicos destacan los i-vectors. Entre los modernos destacan x-vectors, ECAPA-TDNN y embeddings basados en arquitecturas ResNet.

10.5. Limitaciones forenses de los embeddings

No constituyen una huella vocal infalible. Su desempeño depende de calidad de audio, duración disponible, coincidencia de dominio, idioma y condiciones técnicas de grabación.

11. Comparación entre Feature y Embedding

Una feature es una característica extraída directamente de pequeñas ventanas temporales de audio. Ejemplos comunes son MFCC, PLP, pitch, energía y espectrogramas log-Mel.

Un embedding es una representación global derivada de múltiples features, condensada en un solo vector fijo optimizado para discriminar hablantes.

Las features describen información local de la señal. El embedding resume la información total de una muestra en una representación compacta de nivel superior.

Las features forman secuencias cuya longitud depende de la duración del audio. Los embeddings tienen tamaño constante sin importar la duración de la muestra, siempre que exista suficiente señal útil.

Analogía intuitiva

Features = ladrillos
(Pequeñas piezas de información local.)

Embedding = edificio terminado
(Resumen estructurado construido a partir de muchos ladrillos.)

En sistemas actuales se utilizan features espectrales como entrada a redes neuronales profundas que generan embeddings discriminativos como x-vectors o ECAPA.