

SCORES Y METRICAS BÁSICAS

Speaker Recognition en Voz Forense

Índice general

1. SCORING	3
1.1. Scoring en identificación de voz forense	3
1.1.1. Objetivo del scoring	3
1.2. Similitud coseno	4
1.2.1. Normalización de embeddings	4
1.3. Distancia euclidiana	5
1.4. Diferencia entre similitud coseno y distancia euclidiana	5
1.5. Threshold o umbral de decisión	6
1.5.1. Selección del threshold	6
1.6. Errores de decisión	7
1.6.1. Falsa aceptación (FALSE ACCEPTANCE)	7
1.6.2. Falso rechazo (FALSE REJECTION)	7
1.6.3. FAR y FRR	7
1.6.4. Equal Error Rate	7
1.7. Scoring en identificación cerrada y abierta	8
1.7.1. Factores que afectan el score	8
1.7.2. Normalización de scores	9
1.8. Calibración de scores	9
1.8.1. Likelihood Ratio en contexto forense	10
1.9. PLDA como scoring avanzado	10
2. Métricas Básicas	11
2.1. Introducción general	11
2.2. Matriz de confusión en verificación de locutores	11
2.2.1. FAR: False Acceptance Rate	13
2.2.2. FRR: False Rejection Rate	13
2.2.3. Trade-off entre FAR y FRR	14
2.3. ROC Curve	14
2.3.1. AUC: Area Under the Curve	15
2.4. DET Curve	15
2.5. EER: Equal Error Rate	16
2.6. Distribuciones de scores	16
2.7. minDCF: Minimum Detection Cost Function	17
2.7.1. Cómo se obtienen los costos C_{FA} y C_{Miss}	18
2.8. Interpretación forense	18
2.9. Comparación profesional entre modelos	19
2.9.1. Reglas importantes para comparar	19

2.9.2. Ejemplo de tabla resumida para comparar modelos 19

2.9.3. Dimensiones de comparación y métricas asociadas 20

Capítulo 1

SCORING

1.1. Scoring en identificación de voz forense

El *scoring* es la etapa en la que un sistema de reconocimiento de locutor compara dos representaciones numéricas de voz, llamadas *embeddings*, y produce un valor numérico denominado *score*. Este score indica qué tan similares o diferentes son dos muestras de voz.

audio $\rightarrow$ modelo neuronal $\rightarrow$ embedding $\rightarrow$ score $\rightarrow$ decisión

En sistemas modernos, como los basados en *x-vectors* o *ECAPA-TDNN*, cada segmento de voz se transforma en un vector:

$$\mathbf{x} = (x_1, x_2, \dots, x_d)$$

donde d representa la dimensión del embedding. Para comparar dos grabaciones, se utilizan normalmente dos embeddings:

$$\mathbf{x}_{enroll}$$

que representa la voz de referencia, y

$$\mathbf{x}_{test}$$

que representa la voz dubitada o de prueba.

1.1.1. Objetivo del scoring

El objetivo del scoring es asignar un valor que permita estimar si dos muestras de voz provienen del mismo locutor o de locutores diferentes. En términos forenses, se consideran dos hipótesis principales:

H_p : las dos grabaciones provienen del mismo locutor

H_d : las dos grabaciones provienen de locutores distintos

Un score alto suele indicar mayor similitud entre las voces, mientras que un score bajo suele indicar menor similitud. Sin embargo, la interpretación depende del tipo de métrica utilizada. En

medidas de similitud, como la similitud coseno, valores altos indican mayor parecido. En medidas de distancia, como la distancia euclidiana, valores bajos indican mayor parecido.

1.2. Similitud coseno

La similitud coseno es una de las métricas más utilizadas para comparar embeddings de voz. Esta métrica mide el ángulo entre dos vectores, no la distancia directa entre ellos.

$$\cos(\theta) = \frac{\mathbf{x} \cdot \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}$$

donde:

$$\mathbf{x} \cdot \mathbf{y}$$

es el producto punto entre los vectores, y

$$\|\mathbf{x}\|, \|\mathbf{y}\|$$

son las normas o magnitudes de cada vector.

La similitud coseno toma valores entre -1 y 1 . En reconocimiento de locutor, normalmente se espera que dos grabaciones del mismo locutor produzcan embeddings con direcciones similares, por lo que el valor de coseno será alto.

$$\cos(\theta) \approx 1$$

indica alta similitud, mientras que:

$$\cos(\theta) \approx 0$$

indica poca relación entre los vectores.

La ventaja principal de la similitud coseno es que reduce la importancia de la magnitud del vector y se concentra en su dirección. Esto es útil porque la magnitud del embedding puede verse afectada por factores externos como ruido, duración del audio, tipo de micrófono, canal de grabación o compresión.

1.2.1. Normalización de embeddings

Antes de calcular la similitud coseno, es común normalizar los embeddings para que tengan norma unitaria:

$$\tilde{\mathbf{x}} = \frac{\mathbf{x}}{\|\mathbf{x}\|}$$

Después de esta normalización, todos los vectores tienen longitud igual a 1:

$$\|\tilde{\mathbf{x}}\| = 1$$

Esto facilita la comparación entre embeddings, ya que se eliminan diferencias relacionadas con la escala del vector.

1.3. Distancia euclidiana

La distancia euclidiana mide qué tan alejados están dos embeddings como puntos dentro de un espacio vectorial. Se define como:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^d (x_j - y_j)^2}$$

donde x_j y y_j son las componentes de los vectores $\mathbf{x}$ y $\mathbf{y}$, respectivamente.

En este caso, una distancia pequeña indica que los embeddings están cerca y, por tanto, podrían corresponder al mismo locutor. Una distancia grande indica que los embeddings están alejados y probablemente pertenecen a locutores distintos.

$d(\mathbf{x}, \mathbf{y})$ pequeña $\Rightarrow$ mayor similitud

$d(\mathbf{x}, \mathbf{y})$ grande $\Rightarrow$ menor similitud

1.4. Diferencia entre similitud coseno y distancia euclidiana

La similitud coseno y la distancia euclidiana comparan embeddings desde perspectivas distintas. La similitud coseno analiza la dirección de los vectores, mientras que la distancia euclidiana analiza la separación espacial entre ellos.

Coseno: dirección

Euclidiana: distancia

Dos vectores pueden tener la misma dirección pero distinta magnitud. Por ejemplo:

$$\mathbf{x} = (1, 1)$$

$$\mathbf{y} = (10, 10)$$

Estos vectores tienen la misma dirección, por lo que su similitud coseno es alta, pero su distancia euclidiana es grande.

Cuando los embeddings están normalizados, existe una relación directa entre ambas métricas:

$$\|\mathbf{x} - \mathbf{y}\|^2 = 2 - 2\cos(\theta)$$

Esto significa que, si los vectores tienen norma unitaria, maximizar la similitud coseno es equivalente a minimizar la distancia euclidiana.

1.5. Threshold o umbral de decisión

El *threshold* es un valor de corte que permite convertir un score en una decisión. En el caso de la similitud coseno, se acepta que dos voces pertenecen al mismo locutor si:

$$s \geq \tau$$

donde s es el score obtenido y τ es el threshold.

Si:

$$s < \tau$$

entonces se rechaza la coincidencia.

Por ejemplo, si el score obtenido es:

$$s = 0,78$$

y el threshold es:

$$\tau = 0,70$$

entonces:

$$0,78 \geq 0,70$$

por lo tanto, el sistema acepta la comparación como posible mismo locutor.

1.5.1. Selección del threshold

El threshold no debe elegirse de forma arbitraria. Para seleccionarlo se utilizan datos de validación con dos tipos de comparaciones:

Comparaciones genuinas

Son comparaciones entre audios del mismo locutor:

(voz A de Juan, voz B de Juan)

Estas comparaciones deberían producir scores altos.

Comparaciones impostoras

Son comparaciones entre audios de locutores distintos:

(voz de Juan, voz de Pedro)

Estas comparaciones deberían producir scores bajos.

El threshold se elige observando la separación entre las distribuciones de scores genuinos e impostores. En la práctica, estas distribuciones suelen traslaparse, lo que genera errores de clasificación.

1.6. Errores de decisión

Existen dos errores principales asociados al uso de un threshold:

1.6.1. Falsa aceptación (FALSE ACCEPTANCE)

Ocurre cuando el sistema acepta como mismo locutor a dos voces que realmente pertenecen a personas distintas.

FA : aceptar H_p cuando en realidad era H_d

1.6.2. Falso rechazo (FALSE REJECTION)

Ocurre cuando el sistema rechaza dos voces que realmente pertenecen al mismo locutor.

FR : rechazar H_p cuando en realidad era H_p

1.6.3. FAR y FRR

La tasa de falsa aceptación, o *False Acceptance Rate*, se define como:

$$FAR = \frac{\text{número de falsas aceptaciones}}{\text{número total de comparaciones impostoras}}$$

La tasa de falso rechazo, o *False Rejection Rate*, se define como:

$$FRR = \frac{\text{número de falsos rechazos}}{\text{número total de comparaciones genuinas}}$$

Si el threshold aumenta, el sistema se vuelve más estricto. Esto reduce el FAR , pero aumenta el FRR . Si el threshold disminuye, el sistema se vuelve más permisivo. Esto reduce el FRR , pero aumenta el FAR .

1.6.4. Equal Error Rate

El *Equal Error Rate*, o EER , es el punto en el que la tasa de falsa aceptación y la tasa de falso rechazo son iguales:

$$FAR = FRR$$

Un EER bajo indica que el sistema separa mejor las comparaciones genuinas de las impostoras. Por lo tanto, al comparar modelos, aquel con menor EER suele considerarse mejor en términos de discriminación entre locutores.

1.7. Scoring en identificación cerrada y abierta

En identificación cerrada, se asume que el locutor de prueba está dentro de la base de datos. Por lo tanto, el sistema siempre selecciona el locutor con mayor score:

$$\hat{i} = \arg \max_i s_i$$

cuando se usa una métrica de similitud.

Si se usa una métrica de distancia, se selecciona el locutor con menor distancia:

$$\hat{i} = \arg \min_i d_i$$

En identificación abierta, no se asume que el locutor esté en la base de datos. Por ello, además de seleccionar el score máximo, se verifica si supera un threshold:

$$\max_i s_i \geq \tau$$

Si el score máximo supera el threshold, se asigna una identidad. Si no lo supera, se rechaza la identificación.

1.7.1. Factores que afectan el score

El score puede verse afectado por múltiples factores que no necesariamente dependen de la identidad del locutor. Entre ellos se encuentran:

- ruido ambiental,
- duración corta del audio,
- tipo de micrófono,
- canal telefónico,
- compresión del archivo,
- reverberación,
- idioma,
- emoción,
- estado de salud del hablante,
- edad,
- distancia al micrófono.

Estos factores pueden provocar que dos grabaciones del mismo locutor obtengan un score bajo o que dos locutores diferentes obtengan un score relativamente alto.

1.7.2. Normalización de scores

Además de normalizar embeddings, también puede realizarse normalización de scores. Algunas técnicas comunes son:

- Z-norm,
- T-norm,
- S-norm.

Estas técnicas ajustan los scores utilizando cohortes de comparación. Su objetivo es determinar si un score es realmente significativo o si simplemente es alto debido a características generales de una grabación o de un locutor.

1.8. Calibración de scores

Un score crudo no debe interpretarse directamente como una probabilidad. Por ejemplo:

$$s = 0,85$$

no significa que exista un 85 % de probabilidad de que las dos voces pertenezcan al mismo locutor.

Para obtener una interpretación probabilística más adecuada, los scores pueden calibrarse mediante modelos estadísticos, como regresión logística. La calibración puede transformar los scores en log-likelihood ratios:

$$LLR = \log \left(\frac{P(E | H_p)}{P(E | H_d)} \right)$$

donde E representa la evidencia observada.

Si:

$$LLR > 0$$

la evidencia favorece la hipótesis de mismo locutor.

Si:

$$LLR < 0$$

la evidencia favorece la hipótesis de distinto locutor.

Si:

$$LLR = 0$$

la evidencia no favorece claramente a ninguna hipótesis.

1.8.1. Likelihood Ratio en contexto forense

En voz forense, es preferible expresar la fuerza de la evidencia mediante un *Likelihood Ratio*:

$$LR = \frac{P(E | H_p)}{P(E | H_d)}$$

donde:

H_p : mismo locutor

H_d : distinto locutor

Si:

$$LR > 1$$

la evidencia favorece que las voces provengan del mismo locutor.

Si:

$$LR < 1$$

la evidencia favorece que las voces provengan de locutores distintos.

Si:

$$LR = 1$$

la evidencia no favorece ninguna de las dos hipótesis.

1.9. PLDA como scoring avanzado

Una técnica avanzada de scoring es *Probabilistic Linear Discriminant Analysis*, conocida como PLDA. Esta técnica modela dos tipos de variabilidad:

- variabilidad entre locutores,
- variabilidad dentro del mismo locutor.

Su score puede interpretarse como una aproximación a:

$$s \approx \log \frac{P(x_q, x_r | H_p)}{P(x_q, x_r | H_d)}$$

Esto conecta directamente con la interpretación forense basada en likelihood ratios.

La variabilidad entre locutores representa las diferencias reales entre personas distintas. La variabilidad intra-locutor representa los cambios que puede presentar una misma persona debido a ruido, canal, emoción, salud, micrófono o duración del audio.

PLDA intenta responder si dos embeddings son más probables bajo la hipótesis de mismo locutor o bajo la hipótesis de locutores distintos.

Capítulo 2

Métricas Básicas

2.1. Introducción general

En speaker recognition forense el objetivo no es simplemente decir si dos audios son iguales o diferentes, sino evaluar qué tan compatible es la evidencia acústica con dos hipótesis rivales. Usualmente se comparan:

H_p : los audios provienen del mismo hablante

H_d : los audios provienen de hablantes distintos

El sistema recibe dos muestras de voz:

x_q : audio cuestionado

x_r : audio de referencia

y produce un score:

$$s = f(x_q, x_r)$$

donde un score alto suele indicar mayor similitud entre hablantes, mientras que un score bajo indica menor similitud.

2.2. Matriz de confusión en verificación de locutores

La matriz de confusión compara la verdad real contra la decisión del sistema. Definimos:

$$Y = \begin{cases} 1, & \text{mismo hablante} \\ 0, & \text{hablantes distintos} \end{cases}$$

y

$$\hat{Y} = \begin{cases} 1, & \text{aceptar misma identidad} \\ 0, & \text{rechazar} \end{cases}$$

La matriz es:

Real / Predicho	$\hat{Y} = 1$	$\hat{Y} = 0$
$Y = 1$	TP	FN
$Y = 0$	FP	TN

donde:

- TP : true positives, genuinos correctamente aceptados.
- FN : false negatives, genuinos rechazados por error.
- FP : false positives, impostores aceptados por error.
- TN : true negatives, impostores correctamente rechazados.

En speaker verification la matriz se construye sobre **pares de comparación**, no sobre audios individuales.

Para cada par (x_i, x_j) :

$$Y_{ij} = \begin{cases} 1, & spk(i) = spk(j) \\ 0, & spk(i) \neq spk(j) \end{cases}$$

y

$$\hat{Y}_{ij} = \begin{cases} 1, & s_{ij} \geq \tau \\ 0, & s_{ij} < \tau \end{cases}$$

Los conteos dependen del threshold:

$$TP(\tau), \quad FP(\tau), \quad TN(\tau), \quad FN(\tau)$$

Por ejemplo:

$$TP(\tau) = \sum_{Y_{ij}=1} \mathbf{1}[s_{ij} \geq \tau]$$

$$FN(\tau) = \sum_{Y_{ij}=1} \mathbf{1}[s_{ij} < \tau]$$

$$FP(\tau) = \sum_{Y_{ij}=0} \mathbf{1}[s_{ij} \geq \tau]$$

$$TN(\tau) = \sum_{Y_{ij}=0} \mathbf{1}[s_{ij} < \tau]$$

donde $\mathbf{1}[\cdot]$ es la función indicadora.

2.2.1. FAR: False Acceptance Rate

La tasa de falsa aceptación mide la proporción de impostores que fueron aceptados erróneamente.

$$FAR = \frac{FP}{FP + TN}$$

También puede escribirse como probabilidad condicional:

$$FAR = P(\hat{Y} = 1 | Y = 0)$$

En términos de score:

$$FAR(\tau) = P(S_i \geq \tau)$$

donde S_i representa la distribución de scores impostor.

Si $p_i(s)$ es la densidad de scores impostor:

$$FAR(\tau) = \int_{\tau}^{\infty} p_i(s) ds$$

Interpretación:

FAR responde: si comparo dos hablantes distintos, ¿qué probabilidad hay de que el sistema los acepte como si fueran la misma persona?

2.2.2. FRR: False Rejection Rate

La tasa de falso rechazo mide la proporción de genuinos que fueron rechazados erróneamente.

$$FRR = \frac{FN}{TP + FN}$$

También:

$$FRR = P(\hat{Y} = 0 | Y = 1)$$

En términos de score:

$$FRR(\tau) = P(S_g < \tau)$$

donde S_g representa la distribución de scores genuine.

Si $p_g(s)$ es la densidad genuine:

$$FRR(\tau) = \int_{-\infty}^{\tau} p_g(s) ds$$

Interpretación:

FRR responde: si realmente es el mismo hablante, ¿qué probabilidad hay de que el sistema lo rechace?

2.2.3. Trade-off entre FAR y FRR

FAR y FRR tienen una relación inversa respecto al threshold.
Si el threshold aumenta:

$$\tau \uparrow$$

entonces:

$$FAR \downarrow, \quad FRR \uparrow$$

Si el threshold disminuye:

$$\tau \downarrow$$

entonces:

$$FAR \uparrow, \quad FRR \downarrow$$

Esto ocurre porque las distribuciones genuine e impostor suelen solaparse.
El caso ideal sería que no existiera solapamiento:

$$FAR = 0, \quad FRR = 0$$

pero en condiciones reales esto casi nunca ocurre.

2.3. ROC Curve

La curva ROC, Receiver Operating Characteristic, muestra el comportamiento del sistema para todos los thresholds posibles.

Grafica:

$$FPR(\tau) \quad \text{contra} \quad TPR(\tau)$$

donde:

$$TPR = \frac{TP}{TP + FN}$$

y

$$FPR = \frac{FP}{FP + TN}$$

En biometría:

$$FPR = FAR$$

Además:

$$TPR = 1 - FRR$$

La curva ROC es el conjunto:

$$ROC = \{(FPR(\tau), TPR(\tau)) : \tau \in \mathbb{R}\}$$

Un sistema perfecto se ubica cerca de:

$$(FPR, TPR) = (0, 1)$$

Un sistema aleatorio sigue aproximadamente:

$$TPR = FPR$$

2.3.1. AUC: Area Under the Curve

AUC es el área bajo la curva ROC:

$$AUC = \int_0^1 TPR(u) du$$

donde $u = FPR$.

Su interpretación probabilística es:

$$AUC = P(S_g > S_i)$$

Esto significa que AUC mide la probabilidad de que un score genuine elegido al azar sea mayor que un score impostor elegido al azar.

Interpretación general:

- $AUC = 1$: separación perfecta.
- $AUC = 0,5$: sistema aleatorio.
- $AUC < 0,5$: ranking invertido.

Limitación importante:

AUC resume toda la curva ROC, pero en speaker recognition muchas veces interesa la zona de FAR muy baja, por ejemplo 10^{-2} , 10^{-3} o 10^{-4} .

Por eso AUC no debe reportarse sola.

2.4. DET Curve

La curva DET, Detection Error Tradeoff, grafica directamente:

$$FAR(\tau) \quad \text{contra} \quad FRR(\tau)$$

Es decir:

$$DET = \{(FAR(\tau), FRR(\tau)) : \tau \in \mathbb{R}\}$$

A diferencia de ROC, DET muestra ambos errores directamente.

El punto ideal es:

$$(FAR, FRR) = (0, 0)$$

En biometría suele usarse una transformación probit:

$$x = \Phi^{-1}(FAR)$$

$$y = \Phi^{-1}(FRR)$$

donde Φ^{-1} es la inversa de la función de distribución acumulada normal estándar. Esta escala permite observar mejor regiones de error muy bajo.

2.5. EER: Equal Error Rate

El EER es el punto donde:

$$FAR(\tau^*) = FRR(\tau^*)$$

El valor común se llama Equal Error Rate:

$$EER = FAR(\tau^*) = FRR(\tau^*)$$

Interpretación:

EER es la tasa de error en el threshold donde falsas aceptaciones y falsos rechazos son iguales.

Si:

$$EER \downarrow$$

entonces el sistema suele tener mejor capacidad discriminativa.

Sin embargo, EER no representa necesariamente el punto operativo real.

Por ejemplo, un banco puede operar con:

$$FAR = 0,1 \%$$

aunque ese punto no coincida con el EER.

Por lo tanto, EER es útil para benchmarking, pero no debe ser la única métrica.

2.6. Distribuciones de scores

Todo el análisis nace de dos distribuciones:

$$S_g \sim p_g(s)$$

$$S_i \sim p_i(s)$$

donde:

- S_g : scores genuine,
- S_i : scores impostor,
- $p_g(s)$: densidad genuine,
- $p_i(s)$: densidad impostor.

Queremos que:

$$\mu_g \gg \mu_i$$

donde:

$$\mu_g = \text{media de scores genuine}$$

$$\mu_i = \text{media de scores impostor}$$

También queremos baja dispersión:

$$\sigma_g^2, \quad \sigma_i^2$$

Una medida de separabilidad es:

$$d' = \frac{\mu_g - \mu_i}{\sqrt{\frac{\sigma_g^2 + \sigma_i^2}{2}}}$$

Mayor d' implica mejor separación entre genuine e impostor.

Las métricas FAR y FRR corresponden a colas de estas distribuciones:

$$FAR(\tau) = \int_{\tau}^{\infty} p_i(s) ds$$

$$FRR(\tau) = \int_{-\infty}^{\tau} p_g(s) ds$$

2.7. minDCF: Minimum Detection Cost Function

EER trata ambos errores de manera simétrica, pero en la realidad los errores pueden tener costos distintos.

Definimos:

$$C_{FA} : \text{costo de falsa aceptación}$$

$$C_{Miss} : \text{costo de falso rechazo}$$

$$P_{tar} : \text{probabilidad previa de target o genuine}$$

$$1 - P_{tar} : \text{probabilidad previa de impostor}$$

La Detection Cost Function es:

$$DCF(\tau) = C_{Miss}P_{tar}FRR(\tau) + C_{FA}(1 - P_{tar})FAR(\tau)$$

El mínimo costo se define como:

$$\min DCF = \min_{\tau} DCF(\tau)$$

Interpretación:

$\min DCF$ responde: considerando costos reales y frecuencia esperada de casos, ¿cuál es el menor costo alcanzable por el sistema?

2.7.1. Cómo se obtienen los costos C_{FA} y C_{Miss}

Los costos no los aprende automáticamente el modelo. Son parámetros externos definidos por el contexto.

2.8. Interpretación forense

En voz forense no basta reportar:

$$EER, \quad FAR, \quad FRR$$

porque estas métricas describen desempeño promedio en un conjunto de evaluación, pero no necesariamente el peso probatorio de un caso particular.

El marco forense correcto compara hipótesis:

$$H_p : \text{misma fuente}$$

$$H_d : \text{fuente distinta}$$

mediante el likelihood ratio:

$$LR = \frac{P(E|H_p)}{P(E|H_d)}$$

donde E es la evidencia acústica.

Interpretación:

- $LR > 1$: la evidencia favorece H_p .
- $LR < 1$: la evidencia favorece H_d .
- $LR = 1$: la evidencia es neutra.

También puede usarse:

$$\log LR$$

porque facilita la interpretación de valores muy grandes o muy pequeños.

Un error común es decir:

“El sistema tiene EER de 2 %, entonces hay 98 % de certeza.”

Esto es incorrecto. El EER describe un comportamiento agregado, no una probabilidad de culpabilidad ni una certeza individual.

2.9. Comparación profesional entre modelos

Para comparar modelos como x-vector, ECAPA-TDNN, ResNet speaker encoder o Transformers para voz, no basta revisar una sola métrica.

Una comparación rigurosa debe evaluar múltiples dimensiones del sistema, porque cada dimensión responde una pregunta distinta.

2.9.1. Reglas importantes para comparar

1. Usar el mismo dataset.
2. Usar los mismos trials.
3. Usar el mismo protocolo experimental.
4. Comparar curvas DET completas.
5. Revisar EER y minDCF.
6. Evaluar regiones específicas, como $FAR = 1\%$ o $FAR = 0.1\%$.
7. Analizar robustez frente a ruido, duración corta y cambio de canal.
8. Reportar incertidumbre o intervalos de confianza.

Un modelo puede tener menor EER, pero peor desempeño en la región operativa relevante. Por eso no existe un “mejor modelo universal”, sino un mejor modelo para una condición concreta.

2.9.2. Ejemplo de tabla resumida para comparar modelos

Modelo	<i>EER</i>	<i>minDCF</i>	<i>FRR@1%FAR</i>	<i>AUC</i>	<i>Cllr</i>	<i>Latency</i>
x-vector	3,2 %	0,41	11 %	0,962	0,29	18ms
ECAPA-TDNN	1,9 %	0,24	5 %	0,985	0,18	24ms
ResNet-SE	2,1 %	0,27	6 %	0,981	0,20	31ms

2.9.3. Dimensiones de comparación y métricas asociadas

Dimensión de comparación	Métricas recomendadas
Discriminación global	EER, ROC Curve, AUC, DET Curve
Desempeño operativo	minDCF, actDCF, FRR@FAR fija, TPR@FAR fija, Recall@Operating Point
Errores de seguridad	FAR, FPR, False Alarm Rate, Attack Acceptance Rate
Errores de usabilidad	FRR, Miss Rate, False Negative Rate, User Retry Rate
Balance entre errores	EER, HTER (Half Total Error Rate), Balanced Error Rate
Calibración probabilística	Cllr, actDCF, Log Loss, Brier Score, Expected Calibration Error (ECE)
Robustez a ruido/canal	EER por condición, minDCF por condición, SNR sensitivity, Cross-channel EER
Generalización entre dominios	Cross-domain EER, Domain Shift Loss, In-domain vs Out-domain gap
Robustez temporal	Aging EER, Drift Rate, Performance vs Time Gap
Análisis estadístico	Confidence Intervals, Bootstrap CI, Standard Deviation, Significance Tests
Eficiencia computacional	Latency, Inference Time, FLOPS, Throughput, Memory Usage, Model Size
Escalabilidad	Queries per second (QPS), Batch Throughput, Real-time Factor (RTF)
Calidad forense	Cllr, Tippett Plots, LR Validity, Calibration under case conditions
Interpretabilidad y auditoría	Score Stability, Repeatability, Traceability, Reproducibility

Cuadro 2.1: Dimensiones profesionales de comparación entre modelos de speaker recognition y métricas asociadas.