

METRICAS AVANZADAS
Speaker Recognition en Voz Forense

Índice general

0.1. Comparación general entre x-vector y ECAPA-TDNN	3
0.1.1. Precisión	3
0.1.2. Robustez	4
0.1.3. Complejidad	5
0.1.4. Audio corto	6
0.2. Matriz de similitud	7
0.3. Pares target y non-target	8
0.3.1. Pares target	8
0.3.2. Pares non-target	8
0.4. FAR, FRR, TAR y TNR	8
0.4.1. False Acceptance Rate	9
0.4.2. False Rejection Rate	9
0.4.3. True Acceptance Rate	9
0.4.4. True Negative Rate	9
0.5. Equal Error Rate	9
0.6. ROC y AUC	10
0.7. DET Curve	10
0.8. minDCF	10
0.8.1. actDCF	11
0.9. Likelihood Ratio	11
0.9.1. Log-Likelihood Ratio	12
0.9.2. De score a likelihood ratio	12
0.10. Calibración	13
0.10.1. Cllr	13
0.10.2. C_{llr}^{min}	14
0.11. Tippett plots	14
0.12. Empirical Cross-Entropy	15
0.13. Brier Score	15
0.14. d-prime	15
0.15. Fisher Ratio	16
0.16. Normalización de scores	16
0.16.1. Z-norm	16
0.16.2. T-norm	16
0.16.3. S-norm	16
0.17. Métricas para audio corto	16
0.18. Métricas por condición acústica	17
0.19. Matriz de confusión	17

0.20. Métricas de clustering	18
0.21. Variabilidad intra e inter hablante	18
0.22. Tabla recomendada para comparar x-vector y ECAPA-TDNN	19
0.23. Flujo recomendado de evaluación	19

0.1. Comparación general entre x-vector y ECAPA-TDNN

Los modelos **x-vector** y **ECAPA-TDNN** pertenecen a la familia de sistemas basados en embeddings de hablante. Ambos transforman un audio de entrada en un vector numérico que busca capturar información característica del locutor.

Sea x una señal de audio. Un sistema de reconocimiento de hablante aprende una función:

$$f_{\theta}(x) = \mathbf{z}$$

donde:

- x es el audio de entrada;
- f_{θ} es el modelo neuronal entrenado;
- θ representa los parámetros del modelo;
- $\mathbf{z}$ es el embedding del hablante.

Posteriormente, dos audios pueden compararse mediante una función de similitud:

$$s(\mathbf{z}_1, \mathbf{z}_2)$$

Un ejemplo común es la similitud coseno:

$$s(\mathbf{z}_1, \mathbf{z}_2) = \cos(\mathbf{z}_1, \mathbf{z}_2) = \frac{\mathbf{z}_1^{\top} \mathbf{z}_2}{\|\mathbf{z}_1\| \|\mathbf{z}_2\|}$$

Si el score supera cierto umbral τ , se decide que los audios corresponden al mismo hablante:

$$s(\mathbf{z}_1, \mathbf{z}_2) \geq \tau$$

En caso contrario:

$$s(\mathbf{z}_1, \mathbf{z}_2) < \tau$$

se decide que corresponden a hablantes distintos.

0.1.1. Precisión

La precisión se refiere a la capacidad del modelo para separar correctamente pares de audios del mismo hablante y pares de hablantes distintos.

En verificación de hablante se comparan dos hipótesis:

H_p : los dos audios provienen del mismo hablante

H_d : los dos audios provienen de hablantes distintos

Un buen modelo debe producir scores altos cuando H_p es verdadera y scores bajos cuando H_d es verdadera.

x-vector

El sistema x-vector fue durante varios años una arquitectura estándar en speaker recognition. Su idea central es usar una red neuronal tipo TDNN para procesar frames acústicos y luego aplicar una capa de *statistics pooling*.

Dado un conjunto de representaciones temporales:

$$\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_T$$

el statistics pooling resume la información temporal mediante estadísticos como la media y la desviación estándar:

$$\mu = \frac{1}{T} \sum_{t=1}^T \mathbf{h}_t$$
$$\sigma = \sqrt{\frac{1}{T} \sum_{t=1}^T (\mathbf{h}_t - \mu)^2}$$

El embedding final se obtiene a partir de estos estadísticos.

ECAPA-TDNN

ECAPA-TDNN puede verse como una evolución del sistema x-vector. Mantiene la idea de usar una arquitectura basada en TDNN, pero introduce mejoras importantes:

- bloques Res2Net;
- conexiones residuales;
- mecanismos de atención;
- SE-blocks;
- pooling estadístico atento dependiente del canal;
- agregación multi-capa.

Por estas razones, ECAPA-TDNN suele ofrecer mejor precisión que x-vector, especialmente en escenarios donde hay variaciones de canal, ruido, reverberación o audios de corta duración.

0.1.2. Robustez

La robustez mide qué tanto se mantiene estable el sistema cuando el audio se degrada. Una señal observada puede modelarse como:

$$\tilde{x} = h * x + n$$

donde:

- x es la señal limpia;

- h representa el canal o la reverberación;
- $*$ es la operación de convolución;
- n es ruido aditivo;
- $\tilde{x}$ es la señal degradada.

Un sistema robusto debería cumplir aproximadamente:

$$\|f_{\theta}(x) - f_{\theta}(\tilde{x})\| \approx 0$$

Esto significa que el embedding del hablante debería cambiar poco ante perturbaciones acústicas.

Robustez en x-vector

El sistema x-vector puede ser robusto si se acompaña de:

- aumento de datos;
- normalización de embeddings;
- PLDA;
- domain adaptation;
- buen VAD;
- control de duración del audio.

Sin embargo, su arquitectura es menos sofisticada que ECAPA-TDNN para capturar patrones multi-escala y ponderar información relevante.

Robustez en ECAPA-TDNN

ECAPA-TDNN suele ser más robusto debido a sus mecanismos internos. Los SE-blocks permiten recalibrar canales importantes; los bloques Res2Net capturan información en múltiples escalas temporales; y el attentive statistics pooling permite dar mayor peso a frames más informativos.

Por ello, ante ruido o condiciones acústicas complejas, ECAPA-TDNN suele conservar mejor la información del hablante.

0.1.3. Complejidad

La complejidad debe analizarse en dos sentidos:

- complejidad computacional;
- complejidad interpretativa.

Complejidad computacional

De manera general, el costo de un modelo puede pensarse como:

$$\text{Costo} \approx O(P + TC)$$

donde:

- P es el número de parámetros del modelo;
- T es el número de frames del audio;
- C es el costo computacional por frame.

El modelo x-vector suele ser más ligero. ECAPA-TDNN suele tener mayor complejidad debido a sus bloques residuales, mecanismos de atención y procesamiento multi-capa.

Complejidad interpretativa

En voz forense, la interpretabilidad es importante porque los resultados pueden tener implicaciones legales.

- x-vector es más sencillo de explicar.
- ECAPA-TDNN suele ser más preciso, pero más difícil de justificar ante audiencias no técnicas.

Por ello, una estrategia recomendable es usar x-vector como *baseline* y ECAPA-TDNN como modelo moderno principal.

0.1.4. Audio corto

El audio corto representa un problema crítico en voz forense. Si un audio tiene pocos segundos, el número de frames disponibles es pequeño.

Sea:

$$X = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T\}$$

donde T es el número de frames. Cuando T es pequeño, los estadísticos estimados son menos estables.

Por ejemplo, la media temporal:

$$\boldsymbol{\mu} = \frac{1}{T} \sum_{t=1}^T \mathbf{h}_t$$

tiene varianza proporcional a:

$$\text{Var}(\boldsymbol{\mu}) \propto \frac{1}{T}$$

Por tanto, si T disminuye, la varianza aumenta. Esto implica que con audio corto el embedding puede ser menos confiable.

x-vector y audio corto

El modelo x-vector puede degradarse de forma considerable con audio corto porque su statistics pooling depende de tener suficiente información temporal para estimar adecuadamente media y desviación estándar.

ECAPA-TDNN y audio corto

ECAPA-TDNN suele resistir mejor el audio corto gracias a la atención y a sus mecanismos multi-escala. Sin embargo, si el audio es extremadamente corto, también se degrada, ya que no existe suficiente evidencia acústica para caracterizar al hablante.

0.2. Matriz de similitud

La matriz de similitud es una herramienta fundamental para analizar globalmente el comportamiento de los embeddings.

Supongamos que tenemos N audios, con embeddings:

$$\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_N$$

La matriz de similitud se define como:

$$S = \begin{pmatrix} s_{11} & s_{12} & \cdots & s_{1N} \\ s_{21} & s_{22} & \cdots & s_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ s_{N1} & s_{N2} & \cdots & s_{NN} \end{pmatrix}$$

donde:

$$s_{ij} = \cos(\mathbf{z}_i, \mathbf{z}_j) = \frac{\mathbf{z}_i^\top \mathbf{z}_j}{\|\mathbf{z}_i\| \|\mathbf{z}_j\|}$$

Esta matriz permite visualizar:

- qué audios se parecen entre sí;
- qué hablantes forman grupos compactos;
- qué audios son atípicos;
- qué modelo separa mejor hablantes;
- si existen problemas de canal, ruido o duración.

Si se tienen dos modelos, se pueden comparar sus matrices:

$$S^{xvec}$$

$$S^{ecapa}$$

y analizar la diferencia:

$$\Delta S = S^{ecapa} - S^{xvec}$$

Si ECAPA-TDNN incrementa la similitud intra-hablante y reduce la similitud inter-hablante, entonces produce embeddings más discriminativos.

0.3. Pares target y non-target

Para evaluar verificación de hablante, se construyen pares de audios.

0.3.1. Pares target

Son pares donde ambos audios pertenecen al mismo hablante:

$$y_{ij} = 1$$

0.3.2. Pares non-target

Son pares donde los audios pertenecen a hablantes distintos:

$$y_{ij} = 0$$

A partir de estos pares se obtienen dos distribuciones de scores:

$$\{s_{ij} : y_{ij} = 1\}$$

$$\{s_{ij} : y_{ij} = 0\}$$

Idealmente:

$$s_{target} \gg s_{non-target}$$

0.4. FAR, FRR, TAR y TNR

Dado un umbral τ , el sistema decide:

$$s \geq \tau \Rightarrow \text{mismo hablante}$$

$$s < \tau \Rightarrow \text{distinto hablante}$$

0.4.1. False Acceptance Rate

La tasa de falsa aceptación mide la proporción de pares non-target que son aceptados erróneamente como target:

$$FAR(\tau) = P(s \geq \tau \mid H_d)$$

Empíricamente:

$$FAR(\tau) = \frac{\#\{s_i^{non} : s_i^{non} \geq \tau\}}{\#\{s_i^{non}\}}$$

0.4.2. False Rejection Rate

La tasa de falso rechazo mide la proporción de pares target rechazados erróneamente:

$$FRR(\tau) = P(s < \tau \mid H_p)$$

Empíricamente:

$$FRR(\tau) = \frac{\#\{s_i^{tar} : s_i^{tar} < \tau\}}{\#\{s_i^{tar}\}}$$

0.4.3. True Acceptance Rate

$$TAR(\tau) = 1 - FRR(\tau)$$

0.4.4. True Negative Rate

$$TNR(\tau) = 1 - FAR(\tau)$$

0.5. Equal Error Rate

El Equal Error Rate, o EER, es el punto donde la FAR y la FRR son iguales:

$$FAR(\tau^*) = FRR(\tau^*)$$

Por tanto:

$$EER = FAR(\tau^*) = FRR(\tau^*)$$

donde:

$$\tau^* = \arg \min_{\tau} |FAR(\tau) - FRR(\tau)|$$

Un EER bajo indica mejor discriminación. Sin embargo, el EER no evalúa calibración, ni incorpora costos de decisión ni probabilidades previas.

0.6. ROC y AUC

La curva ROC representa:

$$TPR(\tau) = TAR(\tau) = 1 - FRR(\tau)$$

contra:

$$FPR(\tau) = FAR(\tau)$$

para diferentes valores de τ .

El área bajo la curva, AUC, puede interpretarse como:

$$AUC = P(s_{target} > s_{non-target})$$

Es decir, la probabilidad de que un score target elegido al azar sea mayor que un score non-target elegido al azar.

0.7. DET Curve

La curva DET representa FRR contra FAR , normalmente usando escala normal deviate:

$$x = \Phi^{-1}(FAR)$$

$$y = \Phi^{-1}(FRR)$$

donde Φ^{-1} es la inversa de la distribución normal estándar.

La curva DET es especialmente útil en speaker recognition porque permite observar mejor diferencias entre modelos en regiones de baja tasa de error.

0.8. minDCF

La función de costo de detección se define como:

$$C_{det}(\tau) = C_{miss}P_{miss}(\tau)P_{tar} + C_{fa}P_{fa}(\tau)(1 - P_{tar})$$

donde:

- C_{miss} es el costo de rechazar erróneamente un par target;
- C_{fa} es el costo de aceptar erróneamente un par non-target;
- P_{tar} es la probabilidad previa de un par target;
- $P_{miss}(\tau)$ es equivalente a $FRR(\tau)$;
- $P_{fa}(\tau)$ es equivalente a $FAR(\tau)$.

El minDCF se define como:

$$\min DCF = \min_{\tau} C_{det}(\tau)$$

También puede usarse una versión normalizada:

$$\min DCF_{norm} = \frac{\min_{\tau} C_{det}(\tau)}{\min(C_{miss}P_{tar}, C_{fa}(1 - P_{tar}))}$$

El minDCF evalúa el mejor desempeño posible del sistema bajo una configuración determinada de costos y prior.

0.8.1. actDCF

Mientras que el minDCF busca el mejor umbral posible, el actDCF evalúa el sistema usando un umbral específico:

$$actDCF = C_{miss}P_{miss}(\tau_{sys})P_{tar} + C_{fa}P_{fa}(\tau_{sys})(1 - P_{tar})$$

Si:

$$actDCF \gg \min DCF$$

entonces el sistema probablemente tiene un problema de calibración o de selección de umbral.

0.9. Likelihood Ratio

El likelihood ratio es una de las herramientas centrales en ciencia forense. Se define como:

$$LR = \frac{P(E | H_p)}{P(E | H_d)}$$

donde:

- E es la evidencia acústica;
- H_p es la hipótesis de la fiscalía;
- H_d es la hipótesis de la defensa.

La interpretación es:

$$LR > 1 \Rightarrow \text{la evidencia apoya } H_p$$

$$LR = 1 \Rightarrow \text{la evidencia es neutral}$$

$$LR < 1 \Rightarrow \text{la evidencia apoya } H_d$$

Por ejemplo, si:

$$LR = 100$$

entonces la evidencia es 100 veces más probable bajo H_p que bajo H_d .

0.9.1. Log-Likelihood Ratio

En la práctica se trabaja con logaritmos del LR:

$$LLR = \log LR$$

También es frecuente usar:

$$\log_{10} LR$$

o:

$$\log_2 LR$$

Si:

$$\log_{10} LR = 3$$

entonces:

$$LR = 10^3 = 1000$$

Si:

$$\log_{10} LR = -2$$

entonces:

$$LR = 10^{-2} = 0,01$$

Esto indica apoyo a la hipótesis de la defensa.

0.9.2. De score a likelihood ratio

Los modelos x-vector y ECAPA-TDNN no producen directamente likelihood ratios. Generalmente producen scores de similitud:

$$s = g(\mathbf{z}_e, \mathbf{z}_t)$$

Por ejemplo:

$$s = \cos(\mathbf{z}_e, \mathbf{z}_t)$$

Para obtener un LR, es necesario calibrar los scores. Una transformación simple es:

$$\ell = as + b$$

donde:

- s es el score original;
- a y b son parámetros de calibración;
- ℓ es el log-likelihood ratio calibrado.

El objetivo de la calibración es transformar scores arbitrarios en valores interpretables como evidencia forense.

0.10. Calibración

La calibración evalúa si los scores producidos por el sistema tienen una interpretación probabilística adecuada.

Un sistema puede tener buena discriminación pero mala calibración.

- Discriminación: capacidad de ordenar correctamente target y non-target.
- Calibración: capacidad de asignar magnitudes correctas de evidencia.

Un sistema bien calibrado no solo debe asignar scores más altos a pares target, sino que sus likelihood ratios deben reflejar adecuadamente la fuerza de la evidencia.

0.10.1. Cllr

El cost of log-likelihood ratio, C_{llr} , es una métrica fundamental para evaluar sistemas forenses basados en LR.

Si usamos logaritmo base 2, se define como:

$$C_{llr} = \frac{1}{2} \left[\frac{1}{N_{tar}} \sum_{i \in tar} \log_2(1 + 2^{-\ell_i}) + \frac{1}{N_{non}} \sum_{j \in non} \log_2(1 + 2^{\ell_j}) \right]$$

donde:

- $\ell_i = \log_2 LR_i$;
- N_{tar} es el número de pares target;
- N_{non} es el número de pares non-target.

Para pares target se desea:

$$\ell_i \gg 0$$

Para pares non-target se desea:

$$\ell_j \ll 0$$

Por tanto, un valor bajo de C_{llr} indica un buen sistema.

Interpretación del Cllr

- $C_{llr} = 0$ representa un sistema perfecto.
- Valores bajos indican buenos LR.
- Valores cercanos a 1 indican sistemas poco informativos.
- Valores mayores a 1 indican sistemas potencialmente engañosos.

El C_{llr} castiga especialmente los errores fuertes en dirección incorrecta. Por ejemplo, asignar un LR muy alto a un par non-target es un error grave.

0.10.2. C_{llr}^{min}

El C_{llr}^{min} representa el mejor valor posible de C_{llr} después de aplicar una calibración monotónica óptima.

La diferencia:

$$C_{llr}^{cal} = C_{llr} - C_{llr}^{min}$$

mide la pérdida por mala calibración.

Si:

$$C_{llr} \approx C_{llr}^{min}$$

el sistema está bien calibrado.

Si:

$$C_{llr} \gg C_{llr}^{min}$$

el sistema discrimina, pero calibra mal.

0.11. Tippett plots

Los Tippett plots son gráficos utilizados para visualizar la distribución de los likelihood ratios en casos target y non-target.

Normalmente se grafican usando:

$$\log_{10} LR$$

Para casos target, se espera:

$$\log_{10} LR > 0$$

Para casos non-target, se espera:

$$\log_{10} LR < 0$$

Un buen sistema debe producir una separación clara entre ambas distribuciones.

Interpretación forense

Si un caso non-target recibe:

$$\log_{10} LR = 3$$

entonces:

$$LR = 1000$$

Esto significa que el sistema está dando fuerte apoyo a H_p cuando en realidad los hablantes son distintos. Este tipo de error es especialmente grave en contexto forense.

0.12. Empirical Cross-Entropy

La empirical cross-entropy evalúa el comportamiento de los likelihood ratios bajo diferentes probabilidades previas.

Una forma conceptual es:

$$ECE(\pi) = \pi \mathbb{E}_{tar} \left[\log_2 \left(1 + \frac{1-\pi}{\pi} LR^{-1} \right) \right] + (1-\pi) \mathbb{E}_{non} \left[\log_2 \left(1 + \frac{\pi}{1-\pi} LR \right) \right]$$

donde:

$$\pi = P(H_p)$$

Esta métrica permite evaluar la sensibilidad del sistema ante distintos escenarios de probabilidad previa.

0.13. Brier Score

El Brier Score mide el error cuadrático de probabilidades predichas.

Si:

$$\hat{p}_i = P(H_p \mid s_i)$$

y:

$$y_i \in \{0, 1\}$$

entonces:

$$BS = \frac{1}{N} \sum_{i=1}^N (\hat{p}_i - y_i)^2$$

Un Brier Score bajo indica mejores probabilidades calibradas.

Sin embargo, en voz forense suele ser preferible trabajar con LR y C_{llr} .

0.14. d-prime

El índice d' mide la separación entre las distribuciones target y non-target.

Si asumimos:

$$s_{tar} \sim N(\mu_{tar}, \sigma_{tar}^2)$$

$$s_{non} \sim N(\mu_{non}, \sigma_{non}^2)$$

entonces:

$$d' = \frac{\mu_{tar} - \mu_{non}}{\sqrt{\frac{1}{2}(\sigma_{tar}^2 + \sigma_{non}^2)}}$$

Un d' alto indica mejor separación entre distribuciones.

0.15. Fisher Ratio

Otra medida de separación es el Fisher ratio:

$$J = \frac{(\mu_{tar} - \mu_{non})^2}{\sigma_{tar}^2 + \sigma_{non}^2}$$

Un valor alto de J indica que las distribuciones target y non-target están mejor separadas.

0.16. Normalización de scores

En sistemas de speaker recognition puede ser útil normalizar scores para mejorar estabilidad.

0.16.1. Z-norm

$$s' = \frac{s - \mu_Z}{\sigma_Z}$$

0.16.2. T-norm

$$s' = \frac{s - \mu_T}{\sigma_T}$$

0.16.3. S-norm

$$s_{S-norm} = \frac{1}{2} \left(\frac{s - \mu_Z}{\sigma_Z} + \frac{s - \mu_T}{\sigma_T} \right)$$

Estas técnicas ayudan a reducir efectos de canal, cohorte y variabilidad acústica.

0.17. Métricas para audio corto

Como el audio corto es un problema importante en voz forense, se recomienda evaluar por rangos de duración:

$$EER_{<3s}, \quad EER_{3-5s}, \quad EER_{5-10s}, \quad EER_{>10s}$$

También pueden calcularse:

$$C_{llr, <3s}$$

$$minDCF_{<3s}$$

Esto permite detectar si un modelo tiene buen desempeño global, pero falla en audios breves.

0.18. Métricas por condición acústica

También se recomienda evaluar por condiciones como:

- audio limpio;
- ruido;
- reverberación;
- canal telefónico;
- compresión;
- duración corta.

Si se dispone de SNR, puede calcularse:

$$SNR = 20 \log_{10} \left(\frac{\|x\|}{\|n\|} \right)$$

y reportar métricas como:

$$EER_{20dB}, \quad EER_{10dB}, \quad EER_{0dB}$$

0.19. Matriz de confusión

Para un umbral fijo, se puede construir una matriz de confusión:

	Predice mismo	Predice distinto
Mismo real	TP	FN
Distinto real	FP	TN

De ella se derivan:

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = \frac{2Precision \cdot Recall}{Precision + Recall}$$

Sin embargo, estas métricas pueden ser engañosas en speaker verification, ya que normalmente existen muchos más pares non-target que target.

0.20. Métricas de clustering

Si se desea evaluar la estructura geométrica de los embeddings, puede utilizarse el Silhouette Score.

Para un punto i :

$a(i)$ = distancia promedio a puntos del mismo hablante

$b(i)$ = distancia promedio al hablante distinto más cercano

El silhouette individual es:

$$sil(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

El silhouette promedio es:

$$Sil = \frac{1}{N} \sum_{i=1}^N sil(i)$$

Valores cercanos a 1 indican grupos bien separados.

0.21. Variabilidad intra e inter hablante

Otra forma de analizar embeddings es comparar la variabilidad intra-hablante y la variabilidad inter-hablante.

Para el hablante k , con n_k audios:

$$\bar{\mathbf{z}}_k = \frac{1}{n_k} \sum_{i:y_i=k} \mathbf{z}_i$$

La variabilidad intra-hablante se define como:

$$S_W = \sum_{k=1}^K \sum_{i:y_i=k} (\mathbf{z}_i - \bar{\mathbf{z}}_k)(\mathbf{z}_i - \bar{\mathbf{z}}_k)^\top$$

La variabilidad inter-hablante se define como:

$$S_B = \sum_{k=1}^K n_k (\bar{\mathbf{z}}_k - \bar{\mathbf{z}})(\bar{\mathbf{z}}_k - \bar{\mathbf{z}})^\top$$

Un buen sistema debería cumplir:

$$S_B \gg S_W$$

Puede resumirse con:

$$R = \frac{\text{tr}(S_B)}{\text{tr}(S_W)}$$

Un valor alto de R indica mejor separación entre hablantes.

0.22. Tabla recomendada para comparar x-vector y ECAPA-TDNN

Una tabla final de comparación podría tener la siguiente estructura:

Métrica	x-vector	ECAPA-TDNN	Mejor
$EER \downarrow$			
$minDCF \downarrow$			
$actDCF \downarrow$			
$AUC \uparrow$			
$C_{llr} \downarrow$			
$C_{llr}^{min} \downarrow$			
$C_{llr}^{cal} \downarrow$			
$EER_{audiocorto} \downarrow$			
$EER_{ruido} \downarrow$			
$Silhouette \uparrow$			
$\frac{tr(S_B)}{tr(S_W)} \uparrow$			

Las flechas indican:

$\downarrow$ menor es mejor

$\uparrow$ mayor es mejor

0.23. Flujo recomendado de evaluación

Para comparar los modelos de forma seria, se recomienda seguir el siguiente flujo:

1. Extraer embeddings con x-vector.
2. Extraer embeddings con ECAPA-TDNN.
3. Construir matrices de similitud.
4. Crear pares target y non-target.
5. Calcular scores de similitud.
6. Evaluar discriminación mediante EER, ROC, AUC, DET y minDCF.
7. Calibrar scores para obtener log-likelihood ratios.
8. Evaluar calibración mediante C_{llr} , C_{llr}^{min} y C_{llr}^{cal} .
9. Construir Tippett plots.
10. Evaluar por duración, ruido, canal y otras condiciones acústicas.